

TESE DE INVESTIMENTO

A Arquitetura Financeira da Bolha de Infraestrutura de Inteligência Artificial

Anatomia Contábil, Teia de Dependências Corporativas, Fluxo de Capital dos Grandes Agentes de Mercado, Conjuntura Macroeconômica Global e Cenários Quantitativos de Ruptura

Julho de 2026 — Versão 2 (Revisada e Ampliada)

Documento técnico de análise macro-financeira e setorial, destinado a apoiar decisões de alocação de capital. Esta versão amplia a edição anterior com: (i) o mapeamento completo da teia de relações contratuais e acionárias entre hyperscalers, fabricantes de silício, provedores de nuvem GPU-native e startups de fundação; (ii) dados de posicionamento de grandes gestores de capital — fundos soberanos, hedge funds, holdings de venture capital, gestores passivos e operações de compra e venda de ações por parte dos próprios executivos e insiders; (iii) um panorama ampliado da conjuntura macroeconômica global, incluindo Estados Unidos, zona do euro, China e mercados emergentes, com atenção especial ao choque de oferta de energia decorrente do conflito no Oriente Médio iniciado em fevereiro de 2026 e seus efeitos sobre a trajetória de juros; e (iv) cenários quantitativos quantitativos de correção de preços por classe de ativo, segmentados por ordem de impacto temporal.

Este documento não constitui recomendação de investimento, aconselhamento financeiro, contábil ou jurídico. Trata-se de material de análise para fins educacionais e de apoio à decisão. Todas as projeções e cenários quantitativos são estimativas sujeitas a incerteza substancial e não devem ser interpretadas como previsões garantidas. O leitor deve consultar profissionais qualificados antes de tomar decisões de investimento.

Sumário

1	Sumário Executivo e Tese Central	4
2	A Anatomia Contábil da Economia Unitária de IA	5
2.1	Por que o modelo SaaS tradicional não se aplica	5
2.2	As três camadas do Custo dos Produtos Vendidos (COGS) de IA	6
2.3	Onde reside a ilusão contábil	6
2.4	Métricas de auditoria para estresse do modelo de negócio	6
2.4.1	Relação unitária do token	6
2.4.2	O ajuste da remuneração baseada em ações (SBC)	6
2.4.3	Descompasso entre CapEx e Fluxo de Caixa Livre	7
2.5	Churn de coorte como veredicto final do produto	7
2.6	O problema da depreciação: a disputa Burry versus hyperscalers	7
3	Dados Financeiros Consolidados dos Principais Agentes	7
3.1	As quatro grandes hyperscalers: capex, geração de caixa e o teto de 2026	8
3.2	Nvidia: o fornecedor central e seu grau de concentração de risco	8
3.3	OpenAI: a maior concentração de compromissos contratuais do ecossistema	9
3.4	Anthropic: trajetória de receita e a rede de quatro investidores estratégicos	9
3.5	Oracle: o estudo de caso mais avançado de repricing do mercado	10
3.6	Provedores de nuvem GPU-native (“neoclouds”): CoreWeave, Nebius e pares	10
4	A Teia de Dependências: Mapeamento Exaustivo das Relações Corporativas	11
4.1	Por que mapear a teia importa mais do que analisar empresas isoladamente	11
4.2	Nvidia: o centro gravitacional	11
4.3	OpenAI: o nó de maior concentração de compromissos	11

4.4	Anthropic: de startup dependente da Amazon a hub de quatro hyperscalers	11
4.5	Microsoft: o duplo-apostador	12
4.6	Meta: o disruptor da narrativa de escassez	12
4.7	Broadcom, AMD e a corrida por silício alternativo à Nvidia	12
4.8	SoftBank: o financiador cruzado com posição contraditória	12
4.9	Financiamento extrapatrimonial: a migração da dívida para veículos de propósito específico	12
4.10	Diagrama-síntese da teia de dependências	13
5	Limitações Físicas: Silício e Energia como Tetos Rígidos de Expansão	14
5.1	Do gargalo de chips ao gargalo de energia	14
5.2	A corrida por energia nuclear e reatores modulares	14
5.3	Oposição comunitária e restrições regulatórias locais	15
5.4	Prêmio de certeza energética e nova geografia dos data centers	15
5.5	Implicação para a tese de investimento	15
6	Panorama Macroeconômico Global e Perspectivas de Juros	16
6.1	Por que a conjuntura macro importa para a tese de bolha em IA	16
6.2	O choque de energia do conflito no Oriente Médio	16
6.3	Estados Unidos: o giro hawkish do Federal Reserve	16
6.4	Zona do euro: primeira alta de juros do Banco Central Europeu desde 2023	17
6.5	China: crescimento resiliente na superfície, fragilidades estruturais na base	17
6.6	Mercados emergentes e economias exportadoras de energia	17
6.7	Síntese: a convergência de dois ciclos independentes	18
7	Auditoria do Fluxo de Capital dos Grandes Agentes de Mercado	18
7.1	A pergunta central: compra genuína ou posicionamento defensivo sob preços inflados?	18
7.2	Venda recorde de ações por executivos e <i>insiders</i> (2025)	18
7.3	Michael Burry: da posição vendida à tese pública sobre depreciação	19
7.4	Peter Thiel: liquidação integral da posição em Nvidia	20
7.5	SoftBank: a liquidação de US\$ 5,8 bilhões que precedeu a de Thiel	20
7.6	Concentração em índices passivos: risco estrutural não discricionário	20
7.7	Fundos soberanos: postura predominantemente favorável, com uso instrumental da própria tecnologia	21
7.8	Síntese: um mercado de sinais mistos, mas com viés de cautela crescente entre os mais informados	21
8	O Que É Factível e o Que É Excesso: Separando Sinal de Ruído	21
8.1	Princípio metodológico desta seção	21
8.2	O que é factível: evidências de valor econômico real	21
8.3	O que permanece genuinamente incerto	22
8.4	O que constitui excesso especulativo	22
9	Vetores de Ruptura e Gatilhos de Contágio	23
9.1	Tipologia dos gatilhos potenciais	23
9.2	Gatilho 1: revelação de excesso de capacidade (o precedente Meta Compute)	23
9.3	Gatilho 2: reprecificação de crédito e o precedente Oracle	24
9.4	Gatilho 3: falha ou atraso de IPO das startups de fundação	24
9.5	Gatilho 4: choque macroeconômico exógeno prolongado	25
9.6	Gatilho 5: revisão contábil ou regulatória sobre depreciação	25
9.7	Interação entre gatilhos: por que o risco agregado supera a soma das partes	25
10	Cenários Quantitativos de Correção	25
10.1	Nota metodológica	25
10.2	Cenário Base (probabilidade estimada: moderada-alta): “Desinflação Ordenada”	26
10.3	Cenário de Estresse (probabilidade estimada: moderada): “Repricing Abrupto de Crédito”	26
10.4	Cenário Severo (probabilidade estimada: baixa-moderada): “Convergência de Choques”	26
10.5	Sensibilidade dos cenários aos desenvolvimentos macroeconômicos	27
11	Matriz de Exposição por Classe de Ativo e Ordem de Impacto Temporal	27
11.1	Estrutura da matriz	27
11.2	Ativos de primeira ordem: impacto imediato e direto	27
11.3	Ativos de segunda ordem: impacto derivado, com defasagem de trimestres	28

11.4	Ativos de terceira ordem: impacto sistêmico e macroeconômico difuso	28
11.5	Ativos que tendem a se beneficiar no curto e médio prazo	29
11.6	Considerações finais	30

1 Sumário Executivo e Tese Central

O ciclo de investimento em Inteligência Artificial que se desenrola entre 2023 e 2026 constitui, simultaneamente, um avanço tecnológico genuíno e um episódio de má alocação de capital em escala historicamente comparável às maiores manias de infraestrutura do capitalismo industrial — a expansão ferroviária britânica da década de 1840, a eletrificação americana do início do século XX e, mais proximamente, a bolha de fibra óptica de 1999–2001. A tese central deste relatório não é de que a Inteligência Artificial seja desprovida de valor econômico real: a tecnologia já gera receita mensurável, produtividade documentada em determinados casos de uso e um ecossistema de produtos com demanda genuína. A tese é de que o ritmo, o volume e, sobretudo, a *estrutura de financiamento* do investimento em infraestrutura computacional descolaram-se materialmente da capacidade demonstrada de monetização na ponta final da cadeia de valor — e que esse descolamento está ocorrendo simultaneamente a um endurecimento inesperado das condições macroeconômicas globais que reduz a margem de segurança de todo o sistema.

Seis forças convergentes sustentam essa tese e serão desenvolvidas ao longo deste documento:

- (i) **Descompasso entre despesa de capital e geração de caixa livre.** As quatro maiores hyperscalers norte-americanas (Microsoft, Alphabet, Amazon e Meta) projetam gastos combinados de capital da ordem de **US\$ 700 a 725 bilhões em 2026** — alta de aproximadamente 77% sobre os cerca de US\$ 410 bilhões de 2025 — absorvendo uma fração do fluxo de caixa operacional que se aproxima, em alguns casos, de 100%. A Goldman Sachs projeta capex combinado de US\$ 5,3 trilhões entre 2025 e 2030 apenas para essas quatro companhias, e estimativas agregadas para o setor apontam para algo entre US\$ 7 e 8 trilhões entre 2026 e 2031 somando computação, data centers e energia.
- (ii) **Financiamento circular (*round-tripping*) entre investidores estratégicos e startups de fundação**, hoje uma teia muito mais densa do que um simples eixo Microsoft–OpenAI: envolve, simultaneamente, Nvidia, Amazon, Google, Microsoft, AMD, Broadcom, Oracle, SoftBank e um conjunto de provedores de nuvem GPU-native (CoreWeave, Nebius, Lambda) operando em torno de um punhado de startups de fundação (OpenAI, Anthropic, xAI). A OpenAI sozinha acumulou compromissos estimados em mais de **US\$ 1,1 trilhão** distribuídos entre sete fornecedores. A Anthropic, por sua vez, passou a contar simultaneamente com quatro investidores estratégicos que são também seus principais fornecedores de infraestrutura — Amazon, Google, Microsoft e Nvidia — uma configuração que torna praticamente impossível discernir receita de demanda genuína de receita originada em compromissos de investimento cruzado.
- (iii) **Migração acelerada de dívida para fora dos balanços patrimoniais**, via veículos de propósito específico (*Special Purpose Vehicles*, SPVs) estruturados com gestoras de crédito privado (Blue Owl, Apollo, PIMCO, BlackRock). Mais de US\$ 120 bilhões em financiamento de data centers já migraram para essas estruturas extrapatrimoniais em aproximadamente dezoito meses, com projeções de mercado apontando para centenas de bilhões adicionais ao longo de 2026, revivendo preocupações estruturais análogas às de veículos fora de balanço que precederam crises financeiras anteriores.
- (iv) **Descasamento entre o ciclo de depreciação contábil declarado (5 a 6 anos) e a obsolescência física e econômica real dos ativos (estimada por críticos como Michael Burry entre 2 e 3 anos)**, com clusters de gerações anteriores de GPUs perdendo competitividade econômica muito antes do fim do prazo contábil declarado pelas próprias empresas. Segundo essa tese, o setor poderia estar subestimando a depreciação agregada em cerca de **US\$ 176 bilhões entre 2026 e 2028**, inflando artificialmente os lucros reportados.
- (v) **Restrição física de energia elétrica** como teto rígido de expansão, já forçando as hyperscalers a investimentos de *last-resort* em geração nuclear convencional (reativação de usinas como Three Mile Island) e em reatores modulares de pequeno porte (SMR) com prazos de maturação de cinco a dez anos — um horizonte temporal fundamentalmente incompatível com o ciclo de dezoito a trinta e seis meses de obsolescência de GPUs.
- (vi) **Divergência crescente entre o discurso público de otimismo ilimitado e o comportamento revelado dos agentes mais informados do próprio setor**: mais de **US\$ 16 bilhões em vendas de ações por parte de executivos e insiders** das próprias companhias de tecnologia somente em 2025 (Bezos, Huang, Zuckerberg, Dell, Catz, entre outros); a liquidação integral da posição em Nvidia por parte de SoftBank (US\$ 5,8 bilhões) e por Peter Thiel via Thiel Macro (mais de US\$ 100 milhões, correspondendo a cerca de 40% do portfólio do fundo); e posições vendidas explícitas e crescentes por parte de investidores como Michael Burry, cujo fundo Scion chegou a alocar até 80% de seu portfólio em posições bearish sobre Nvidia, Palantir, Oracle e ETFs de semicondutores. Esse padrão sugere que uma

parcela notável de capital sofisticado está se posicionando de forma defensiva ou diretamente contrária à narrativa de crescimento ininterrupto, mesmo enquanto o preço dos ativos permanece, em grande medida, próximo de máximas históricas.

O evento mais recente e mais informativo deste ciclo — a revelação, em 1º de julho de 2026, de que a Meta está desenvolvendo uma unidade de negócios (*Meta Compute*) para revender capacidade computacional ociosa e acesso a modelos hospedados a clientes externos — deve ser lido como o primeiro reconhecimento público, por parte de uma hyperscaler de primeira linha, de que a premissa fundacional de “escassez perpétua de capacidade” pode não se sustentar integralmente. A reação de mercado a este evento — valorização de quase 9% nas ações da própria Meta em contraste com quedas de dois dígitos percentuais em provedores de nuvem GPU-*native* como CoreWeave (-14%) e Nebius (-17%), além de quedas expressivas em fabricantes de memória e semicondutores — ilustra a mecânica de *repricing* que se espera replicada, em maior escala, caso o padrão se generalize a outras hyperscalers.

Paralelamente, e de forma até certo ponto independente da dinâmica específica de IA, a conjuntura macroeconômica global sofreu, entre fevereiro e junho de 2026, um choque significativo: o conflito armado envolvendo Irã, Israel e Estados Unidos provocou o que a Agência Internacional de Energia classificou como “a maior ruptura de oferta da história do mercado global de petróleo”, com o fechamento parcial do Estreito de Ormuz interrompendo cerca de 20% da oferta mundial de petróleo e elevando o Brent a picos próximos de US\$ 120 por barril antes de recuar para a faixa de US\$ 85–95 após acordos de cessar-fogo frágeis e sucessivamente renovados. Esse choque de oferta elevou as expectativas de inflação nos Estados Unidos, levando o Federal Reserve — sob a nova presidência de Kevin Warsh, empossado em maio de 2026 — a um recuo material da postura de flexibilização monetária: a projeção mediana de juros para o final de 2026 subiu de 3,4% em março para 3,8% em junho, com os mercados precificando a possibilidade concreta de uma alta adicional de juros, em vez dos cortes anteriormente esperados. Esse é um desenvolvimento crucial para a tese deste relatório: um ambiente de “juros mais altos por mais tempo” eleva o custo de capital exatamente no momento em que as hyperscalers e as startups de fundação mais dependem de financiamento externo — via dívida corporativa, veículos extrapatrimoniais e crédito privado — para sustentar o ritmo de expansão.

Este relatório está estruturado da seguinte forma: a Seção 2 estabelece a anatomia contábil da economia unitária de IA; a Seção 3 apresenta os dados financeiros consolidados das principais companhias envolvidas; a Seção 4 mapeia de forma exaustiva a teia de relações contratuais e acionárias entre todas as empresas relevantes do ecossistema; a Seção 5 examina as limitações físicas de silício e energia; a Seção 6 posiciona a tese dentro do panorama macroeconômico global (Estados Unidos, zona do euro, China e mercados emergentes); a Seção 7 audita o fluxo de capital dos grandes agentes de mercado — fundos soberanos, hedge funds, gestores passivos e *insiders* — para aferir se a alta recente reflete compra genuína ou posicionamento defensivo sob preços inflados; a Seção 8 separa o que do otimismo do setor é factível do que constitui excesso especulativo; a Seção 9 mapeia os vetores de ruptura e gatilhos de contágio; a Seção 10 apresenta cenários quantitativos de correção; e a Seção 11 conclui com uma matriz de exposição por classe de ativo, ordenada por ordem de impacto temporal (primeira, segunda e terceira ordem), incluindo os ativos que tendem a se beneficiar de uma eventual correção.

Nota metodológica sobre incerteza

Todas as cifras apresentadas neste documento refletem dados públicos disponíveis até o início de julho de 2026, oriundos de demonstrações financeiras, registros regulatórios (13F, 10-K, 10-Q), reportagens de imprensa especializada e estimativas de casas de análise. Compromissos contratuais plurianuais anunciados (como os da OpenAI) representam obrigações declaradas, não necessariamente desembolsos já realizados, e estão sujeitos a renegociação, atraso ou cancelamento. Cenários de correção apresentados na Seção 10 são estimativas qualitativo-quantitativas baseadas em analogias históricas e não constituem previsões pontuais.

2 A Anatomia Contábil da Economia Unitária de IA

2.1 Por que o modelo SaaS tradicional não se aplica

A indústria de tecnologia acostumou-se, ao longo de duas décadas de expansão do modelo de Software como Serviço (SaaS), a margens brutas estruturais entre 75% e 85%, sustentadas por um custo marginal de servir o usuário adicional próximo de zero. A Inteligência Artificial generativa rompe essa premissa fundacional: cada requisição de um usuário consome capacidade de processamento física e mensurável, energia elétrica e refrigeração, em uma proporção diretamente vinculada ao volume de uso. O custo marginal deixa de ser desprezível e passa a ser persistente, real e crescente com a escala.

Observação 1. A distinção entre custo marginal decrescente (característica de software puro) e custo marginal persistente (característica de infraestrutura física com componente de consumo) é a chave analítica para entender por que múltiplos de avaliação historicamente aplicados a empresas de software não podem ser transpostos, sem ajuste, para empresas de Inteligência Artificial.

2.2 As três camadas do Custo dos Produtos Vendidos (COGS) de IA

O COGS de uma empresa de Inteligência Artificial pode ser decomposto em três componentes estruturalmente distintos:

- (a) **Custo de computação-base (*cloud/infraestrutura*):** o aluguel bruto de instâncias de processamento junto a provedores de nuvem (AWS, Azure, Google Cloud Platform, CoreWeave, Nebius) necessário para manter o sistema operacional.
- (b) **Custo de inferência dedicada:** cada requisição executa uma passagem direta (*forward pass*) pelos parâmetros do modelo. Quando o modelo é proprietário e de grande escala, o custo de hardware dedicado é elevado; quando a empresa opera via interfaces de programação de terceiros (OpenAI, Anthropic), a despesa é indexada linearmente ao volume de tokens processados.
- (c) **Armazenamento e indexação vetorial:** a manutenção de bancos de dados vetoriais para busca semântica e geração aumentada por recuperação (*Retrieval-Augmented Generation*, RAG) consome memória de acesso aleatório e processamento contínuo, mesmo em períodos de baixa demanda.

2.3 Onde reside a ilusão contábil

A prática contábil observada em uma parcela relevante das empresas do setor consiste em capitalizar despesas de desenvolvimento e ajuste fino (*fine-tuning*) de modelos como Pesquisa e Desenvolvimento (classificadas como despesa operacional, OpEx) ou, em casos mais agressivos, como Ativo Intangível no balanço patrimonial (CapEx), excluindo-as do COGS reportado. Esse tratamento infla artificialmente a margem bruta declarada, aproximando-a dos patamares de 75–85% típicos de SaaS puro, quando a margem real de entrega do produto — aqui definida como Margem de Inferência — frequentemente situa-se em 30% ou abaixo disso.

Definição 1 (Margem de Inferência Real). *Define-se a Margem de Inferência Real como:*

$$\text{Margem de Inferência Real} = \frac{\text{Receita} - (\text{Custo de API/GPU} + \text{Custo de Armazenamento Vetorial})}{\text{Receita}}$$

Valores abaixo de 40% indicam um modelo de negócio de viabilidade duvidosa no longo prazo sem ganhos substanciais de eficiência (quantização de modelos, otimização de motores de inferência como vLLM, ou redução do custo por token via novas arquiteturas de silício).

2.4 Métricas de auditoria para estresse do modelo de negócio

2.4.1 Relação unitária do token

A métrica mais direta de sustentabilidade unitária compara o custo de processar um milhão de tokens (*Cost per Million tokens*, CPM) com a receita gerada pelo mesmo volume (*Revenue per Million tokens*, RPM):

$$\text{Índice de Eficiência} = \frac{\text{RPM}}{\text{CPM}}$$

Quando esse índice situa-se abaixo de $3\times$ a $5\times$, a empresa está escalando uma operação que consome caixa na mesma proporção em que adquire clientes, caracterizando crescimento não lucrativo por construção.

2.4.2 O ajuste da remuneração baseada em ações (SBC)

Um artifício recorrente na apresentação de resultados ajustados consiste em somar de volta ao lucro a Remuneração Baseada em Ações (*Stock-Based Compensation*, SBC). A guerra por talento em engenharia de IA elevou pacotes de remuneração a patamares que, se pagos integralmente em caixa, comprometeriam de forma visível o fluxo de caixa operacional. Ao substituir caixa por ações, a despesa não aparece no Demonstrativo de Fluxo de Caixa como saída operacional, mas dilui de forma real e permanente a participação acionária dos investidores existentes.

$$\text{Fluxo de Caixa Operacional Ajustado (Real)} = \text{Fluxo de Caixa Operacional Reportado} - \text{SBC}$$

2.4.3 Descompasso entre CapEx e Fluxo de Caixa Livre

Nas empresas de capital aberto, o indicador mais direto de saturação ou de excesso especulativo é o comportamento relativo entre o investimento em bens de capital (CapEx) e o Fluxo de Caixa Livre (FCF) gerado:

Cenário Sustentável	Sinal de Alerta (Padrão de Bolha)
O CapEx cresce, mas a receita de serviços e o FCF acompanham a trajetória de crescimento com defasagem de 2 a 3 trimestres.	O CapEx em data centers e GPUs dobra ano a ano, mas o FCF estagna ou recua, indicando que a infraestrutura adquirida não encontra demanda pagante na mesma velocidade de instalação.

2.5 Churn de coorte como veredicto final do produto

Em ciclos de adoção de novas tecnologias, a retenção inicial de usuários é sistematicamente inflada por um efeito de novidade (*hype*): o usuário testa a ferramenta, reconhece seu valor demonstrativo, mas não necessariamente a integra ao fluxo de trabalho recorrente. A análise da curva de retenção por coorte revela o veredicto real do produto:

- **Curva em L (sinal de alerta):** a retenção despenca nos primeiros três meses e estabiliza próxima de zero, indicando que o produto constitui uma utilidade passageira, com Custo de Aquisição de Cliente (CAC) que jamais será recuperado (*CAC Payback* impossível).
- **Curva em sorriso (retenção líquida de receita superior a 100%):** a coorte perde usuários marginais ao longo do tempo, mas os usuários remanescentes ampliam de forma consistente seu consumo de tokens e chamadas de API, compensando as perdas. Este é o único padrão compatível com sobrevivência de longo prazo de uma empresa de Inteligência Artificial.

2.6 O problema da depreciação: a disputa Burry *versus* hyperscalers

Nenhum ponto da anatomia contábil do setor gerou tanta controvérsia pública quanto o prazo de depreciação atribuído aos aceleradores gráficos (GPUs). Entre novembro e dezembro de 2025, o investidor Michael Burry — tornado célebre por ter antecipado a crise das hipotecas *subprime* de 2008 — publicou uma série de análises argumentando que as hyperscalers estariam depreciando GPUs da Nvidia ao longo de cinco a seis anos, quando o ciclo real de renovação de produto da própria Nvidia (aproximadamente dois a três anos) tornaria essa premissa contábil artificialmente otimista. Segundo sua estimativa, essa prática poderia levar a uma subestimação agregada de depreciação da ordem de **US\$ 176 bilhões entre 2026 e 2028**, implicando que os lucros reportados por companhias como Oracle e Meta poderiam estar superestimados em, respectivamente, cerca de 27% e 21% até 2028.

As duas leituras do debate sobre depreciação

- Leitura cética (Burry):** o ciclo de produto da Nvidia — H100 em 2022, Blackwell em 2024, Rubin a partir de 2026 — torna cada geração de GPU obsoleta para treinamento de fronteira em cerca de dezoito a trinta e seis meses. Estender a depreciação contábil para além desse período constitui, na leitura mais crítica, uma forma de engenharia de resultados que infla lucros correntes às custas de baixas contábeis futuras.
- Leitura defensiva (setor):** hyperscalers e a própria Nvidia argumentam que existe um “modelo em cascata” de utilização — GPUs que deixam de ser competitivas para treinamento de modelos de fronteira continuam economicamente úteis para inferência, renderização em nuvem e cargas de trabalho de menor exigência computacional, o que justificaria uma vida útil combinada mais longa. A CoreWeave, por exemplo, argumenta que chips A100 mais antigos preservam cerca de 95% do valor original em contratos vencidos, uma evidência empírica favorável à tese defensiva.

O ponto relevante para efeitos desta tese de investimento não é resolver definitivamente essa disputa técnica — que carece de precedente histórico suficiente para arbitragem conclusiva — mas reconhecer que sua própria existência, movendo-se do nicho de equipes técnicas de contabilidade para o centro do debate de mercado, constitui evidência de que os múltiplos de avaliação do setor carregam premissas contábeis materialmente contestadas e não uniformemente auditadas por padrões comuns entre concorrentes.

3 Dados Financeiros Consolidados dos Principais Agentes

3.1 As quatro grandes hyperscalers: capex, geração de caixa e o teto de 2026

O núcleo financeiro do ciclo de investimento em IA é composto por quatro companhias — Microsoft, Alphabet (Google), Amazon e Meta Platforms — cujo capex combinado passou de aproximadamente US\$ 226 bilhões em 2024 para cerca de US\$ 410 bilhões em 2025 e uma guidance de **US\$ 700 a 725 bilhões para 2026**, um salto de aproximadamente 77% em um único ano e o terceiro ano consecutivo de crescimento superior a 60%.

Empresa	Capex 2025	Capex 2026 (guidance)	Var. YoY	Observações
Amazon	US\$ 125 bi	US\$ 195–200 bi	+56–60%	Maior gasto absoluto; AWS cresceu 28% a/a; chips Trainium com <i>run-rate</i> de US\$ 20 bi
Microsoft	US\$ 90 bi	US\$ 190 bi	+111%	RPO comercial de US\$ 627 bi (quase dobrou); Azure “capacity constrained” segundo Nadella
Alphabet (Google)	US\$ 91–125 bi	US\$ 175–190 bi	+40–90%	<i>Backlog</i> do Google Cloud saltou para mais de US\$ 460 bi; capex elevado duas vezes ao longo do ano
Meta Platforms	US\$ 72 bi	US\$ 125–145 bi	+74–100%	Elevou guidance duas vezes citando custos de memória; sem nuvem pública para monetizar diretamente
Total (4 grandes)	≈ US\$ 388–410 bi	≈ US\$ 700–725 bi	+77%	Projeção Goldman Sachs: US\$ 5,3 tri combinados entre 2025–2030

Intensidade de capital em relação à receita (CreditSights, início de 2026)

Como proporção da receita, o capex projetado para 2026 atinge níveis sem precedente histórico recente para empresas de tecnologia de grande porte: **86% para a Oracle, 54% para a Meta, 47% para a Microsoft, 46% para a Alphabet e 25% para a Amazon**. Para efeito de comparação, o capex conjunto das hyperscalers em 2026 supera o gasto militar combinado de Alemanha, França, Reino Unido, Japão, Itália e Canadá, e aproxima-se do valor de mercado agregado das bolsas de vários países europeus de porte médio.

O financiamento desse volume de investimento já não se apoia exclusivamente em caixa operacional: as hyperscalers emitiram cerca de US\$ 108 bilhões em dívida apenas em 2025, com projeções de mercado apontando para até US\$ 1,5 trilhão em emissões de dívida ao longo dos próximos anos, somando-se ao crescente uso de veículos extrapatrimoniais detalhados na Seção 4.4.

3.2 Nvidia: o fornecedor central e seu grau de concentração de risco

A Nvidia consolidou-se como o ponto de convergência financeiro de todo o ecossistema. No ano fiscal de 2026 (encerrado em janeiro de 2026), a companhia reportou receita recorde de US\$ 215,9 bilhões, alta de 65% sobre o ano anterior, dos quais US\$ 193,7 bilhões (89,7% do total) originaram-se do segmento de data center. No primeiro trimestre do ano fiscal de 2027 (encerrado em abril de 2026), a receita atingiu um novo recorde de US\$ 81,6 bilhões, alta de 85% sobre o ano anterior, com o segmento de data center crescendo 92% para US\$ 75,2 bilhões — uma trajetória anualizada que se aproxima de US\$ 326 bilhões. A companhia tornou-se, em outubro de 2025, a primeira da história a atingir uma capitalização de mercado de US\$ 5 trilhões, patamar em torno do qual oscila desde então.

Observação 2. *Cerca de metade da receita de data center da Nvidia já se origina de hyperscalers (aproximadamente US\$ 38 bilhões no trimestre mais recente), enquanto a outra metade vem de provedores de nuvem GPU-native, startups de fundação e clientes soberanos. Essa concentração implica que a saúde financeira da Nvidia está diretamente amarrada à capacidade continuada desses mesmos clientes — vários dos quais também são, simultaneamente, seus investidores e investidos — de sustentar o ritmo de gastos.*

A companhia opera com margens brutas GAAP de aproximadamente 75%, patamar historicamente elevado para uma fabricante de semicondutores, mas que a expõe de forma desproporcional a qualquer desaceleração de demanda, dado o peso do segmento de data center na receita total. Adicionalmente, a Nvidia declarou não estar assumindo receita de data center oriunda da China devido a controles de exportação, deixando um eventual afrouxamento regulatório como fonte de *upside* não precificado — mas também como fonte de risco político binário.

3.3 OpenAI: a maior concentração de compromissos contratuais do ecossistema

A OpenAI acumulou, ao longo de 2025, compromissos de infraestrutura estimados em mais de **US\$ 1,1 trilhão** distribuídos entre sete fornecedores principais:

Fornecedor	Compromisso	Natureza do acordo
Broadcom	US\$ 350 bi	Co-desenho de aceleradores customizados; 10 GW de capacidade até 2029
Oracle	US\$ 300 bi	Projeto Stargate; hospedagem em nuvem por cinco anos a partir de 2027
Microsoft (Azure)	US\$ 250 bi	Capacidade de nuvem; Microsoft mantém direitos de revenda até 2032
Nvidia	US\$ 100 bi	Nvidia investe até US\$ 100 bi na OpenAI em troca de compromisso de compra de GPUs para 10 GW de novos data centers
AMD	US\$ 90 bi	6 GW de aceleradores Instinct; <i>warrant</i> de até 10% do capital da AMD concedido à OpenAI
Amazon (AWS)	US\$ 38 bi	Acesso imediato a GPUs Nvidia GB200/GB300 via EC2 UltraServers
CoreWeave	US\$ 22 bi	Direitos de uso de data center através de 2029
Total estimado	> US\$ 1,1 tri	Período de execução: 2025–2035

Contra esses compromissos, a posição financeira reportada da OpenAI mostra receita anualizada de aproximadamente **US\$ 25 bilhões** em fevereiro de 2026 (com relatos mais recentes de *The Information* apontando algo entre US\$ 24–25 bilhões em abril), margem bruta de cerca de 33%, e uma trajetória de queima de caixa projetada em aproximadamente **US\$ 27 bilhões em 2026** e **US\$ 63 bilhões em 2027**. A empresa não projeta fluxo de caixa positivo antes de 2030. Em 31 de março de 2026, a OpenAI fechou uma rodada de financiamento de US\$ 122 bilhões a uma avaliação pós-investimento de US\$ 852 bilhões, liderada pela SoftBank com participação de Nvidia, Microsoft e Amazon — os próprios fornecedores estratégicos tornando-se também investidores diretos, um padrão de financiamento circular que será detalhado na Seção 4. Em 8 de junho de 2026, a companhia protocolou confidencialmente pedido de abertura de capital (IPO) nos Estados Unidos, mirando avaliação superior a US\$ 1 trilhão, com relatos subsequentes de possível atraso do processo para 2027 e discussões preliminares sobre uma participação de 5% do governo americano no capital da empresa.

3.4 Anthropic: trajetória de receita e a rede de quatro investidores estratégicos

A Anthropic apresentou, ao longo de 2025 e 2026, uma das trajetórias de crescimento de receita mais acentuadas já registradas por uma empresa de tecnologia: de aproximadamente US\$ 1 bilhão em receita anualizada no início de 2025 para US\$ 9 bilhões ao final do ano, US\$ 14 bilhões em fevereiro de 2026, US\$ 19 bilhões em março, US\$ 30 bilhões em abril e cerca de **US\$ 45–47 bilhões em maio de 2026**. Diferentemente da OpenAI, cuja receita é majoritariamente proveniente de assinaturas de consumidores finais (cerca de 85% do total, a maior parte gratuita), a receita da Anthropic é predominantemente corporativa: mais de 500 empresas gastam acima de US\$ 1 milhão anuais na plataforma Claude, incluindo oito das dez maiores empresas do índice Fortune 10. Segundo relatos de mercado referentes à rodada de financiamento em curso, a companhia projetava receita de US\$ 10,9 bilhões apenas no segundo trimestre de 2026 — mais que o dobro do primeiro trimestre — com seu primeiro lucro operacional trimestral projetado em torno de US\$ 559 milhões.

Do lado do financiamento e da infraestrutura, a Anthropic consolidou uma configuração sem precedentes de dependência cruzada: em novembro de 2025, Microsoft e Nvidia anunciaram investimentos combinados de até US\$ 15 bilhões (US\$ 5 bi e US\$ 10 bi, respectivamente) elevando a avaliação da companhia para

a faixa de US\$ 350 bilhões, com a contrapartida de que a Anthropic se comprometeu a comprar US\$ 30 bilhões em capacidade de nuvem Azure e capacidade adicional de até 1 gigawatt usando sistemas Nvidia. Essa transação se soma às relações preexistentes com Amazon — provedor de nuvem primário e principal parceiro de treinamento desde 2023 e 2024, respectivamente, incluindo o data center dedicado Project Rainier de US\$ 11 bilhões baseado em chips Trainium 2 — e Google, que já era investidora e forneceu, junto com a Broadcom, um acordo subsequente de aproximadamente 3,5 gigawatts de capacidade de TPUs de próxima geração a partir de 2027. Rodadas subsequentes elevaram a avaliação da companhia para a faixa de US\$ 350 a quase US\$ 965 bilhões em relatos de meados de 2026, com investidores incluindo Coatue, GIC (fundo soberano de Singapura), Iconiq e Sequoia Capital — esta última também investidora da rival OpenAI.

Sinal de Alerta 1. *A Anthropic tem, simultaneamente, como investidores estratégicos e fornecedores de infraestrutura essencial: Amazon, Google, Microsoft e Nvidia. Essa configuração — em que os principais provedores de capacidade computacional também detêm participação acionária direta na empresa que consome essa capacidade — é estruturalmente idêntica ao padrão de financiamento circular já identificado no caso Nvidia–OpenAI, e se replica, com participantes distintos, em praticamente todas as startups de fundação relevantes do setor.*

3.5 Oracle: o estudo de caso mais avançado de repricing do mercado

Nenhuma companhia do ecossistema ilustra de forma mais nítida a transição de otimismo para ceticismo do mercado do que a Oracle. A companhia acumulou uma carteira de Obrigações de Performance Remanescentes (*Remaining Performance Obligations*, RPO) que evoluiu de aproximadamente US\$ 130 bilhões em 2024 para US\$ 523 bilhões em dezembro de 2025 (alta de 438% ano contra ano) e US\$ 638 bilhões no relatório mais recente (julho de 2026) — um crescimento de 363% em doze meses. Estima-se que mais da metade dessa carteira, cerca de US\$ 300 bilhões, esteja concentrada em um único cliente: a OpenAI, através do contrato de nuvem do Projeto Stargate.

O mercado tratou essa carteira, ao longo de 2025, como receita futura garantida, elevando as ações da Oracle a uma máxima histórica de US\$ 346 em setembro de 2025. Entre então e julho de 2026, contudo, as ações recuaram mais de 55–59%, negociando na faixa de US\$ 142–160, à medida que investidores passaram a reprecificar essa mesma carteira não mais como receita garantida, mas como uma aposta financiada por dívida em um único cliente ainda não lucrativo. Os fundamentos que sustentam essa reavaliação incluem:

- **Fluxo de caixa livre negativo** de aproximadamente US\$ 13 a 24 bilhões (a depender do período de referência), decorrente de capex que salta 162% para cerca de US\$ 56 bilhões no ano fiscal de 2026, com projeção de US\$ 70 bilhões no ano fiscal de 2027;
- **Dívida total superior a US\$ 130–156 bilhões**, com relação dívida/patrimônio de aproximadamente 3,28× — patamar de alavancagem incomum para uma empresa de tecnologia madura;
- **Spreads de Credit Default Swaps (CDS)** que atingiram máximas históricas antes de recuar parcialmente após a companhia anunciar planos de captar entre US\$ 45 e 50 bilhões adicionais em dívida e capital ao longo de 2026;
- **Corte de aproximadamente 21.000 postos de trabalho** (cerca de 13% do quadro de funcionários), medida vista por analistas como sinal de disciplina de custos forçada pela pressão de caixa;
- **Conversão lenta do backlog em receita**: apenas cerca de 12% da carteira de US\$ 638 bilhões deve se converter em receita reconhecida nos próximos doze meses, com o restante distribuído ao longo de oito a dez anos;
- **Adiamento do IPO da OpenAI** para proteger o piso de avaliação de US\$ 1 trilhão pretendido por Sam Altman, prolongando o período em que a Oracle carrega infraestrutura não monetizada sem o alívio de liquidez que um evento de listagem da OpenAI proporcionaria.

O caso Oracle constitui, portanto, o precedente mais próximo disponível para avaliar como o mercado reage quando a narrativa de “backlog garantido” financiado por dívida encontra dúvidas concretas sobre a capacidade de pagamento do cliente-âncora — um padrão de risco de concentração que se replica, em menor escala, em praticamente todos os provedores de infraestrutura GPU-native analisados na Seção 4.

3.6 Provedores de nuvem GPU-native (“neoclouds”): CoreWeave, Nebius e pares

Os provedores de nuvem especializados em capacidade GPU — CoreWeave, Nebius, Lambda e correlatos — representam o elo mais alavancado e mais dependente de um número reduzido de clientes-âncora dentro da cadeia de valor. A CoreWeave, por exemplo, financiou parte relevante de sua expansão através de dívida

classificada como *high-yield* (não-investment-grade), com *spreads* de CDS em máximas recordes, tornando-a uma das companhias mais sensíveis a qualquer sinal de desaceleração de demanda de seus clientes hyperscalers e startups de fundação. Como discutido na Seção 1 e detalhado na Seção 9, o anúncio da Meta Compute em julho de 2026 provocou quedas de 14% e 17%, respectivamente, nas ações de CoreWeave e Nebius em uma única sessão — evidência direta de que o mercado já precifica essas companhias como as mais vulneráveis a qualquer excesso de capacidade ofertado por clientes que também são potenciais concorrentes.

4 A Teia de Dependências: Mapeamento Exaustivo das Relações Corporativas

4.1 Por que mapear a teia importa mais do que analisar empresas isoladamente

A crítica mais recorrente ao ciclo de investimento em IA concentra-se no conceito de *round-tripping*, ou financiamento circular: uma situação em que o mesmo capital circula entre um número relativamente pequeno de agentes através de papéis alternados de investidor, fornecedor e cliente, criando a aparência de demanda genuína e crescente quando, em parte, o que se observa é a reciclagem do mesmo capital através de contratos entrelaçados. Compreender essa teia é indispensável para qualquer análise de risco sistêmico, porque a falha ou desaceleração de um único nó pode se propagar rapidamente para múltiplos outros através de canais contratuais, de equity e de dívida compartilhada.

4.2 Nvidia: o centro gravitacional

A Nvidia ocupa uma posição estruturalmente única: é simultaneamente fornecedora de hardware essencial e investidora direta em praticamente todos os seus maiores clientes.

Contraparte	Natureza da relação com a Nvidia
OpenAI	Investimento de até US\$ 100 bi em troca de compromisso de compra de GPUs para 10 GW de capacidade; maior single-deal do ecossistema
Anthropic	Investimento de até US\$ 10 bi; parceria de engenharia para otimizar modelos Claude em arquiteturas Grace Blackwell e Vera Rubin
xAI	Investimento direto na rodada de capital da xAI; fornecimento de GPUs para o cluster Colossus
Mistral AI	Participação minoritária na rodada de capital europeia
Microsoft, Amazon, Google, Meta	Clientes diretos de GPUs em escala; adicionalmente, competem parcialmente com a Nvidia ao desenvolver silício próprio (TPU, Trainium, MTIA, MAIA)
CoreWeave, Nebius, Lambda	Nvidia apoiou o surgimento desses provedores GPU-native como canal de distribuição alternativo aos hyperscalers tradicionais
Oracle	Cliente âncora de GPUs para o Projeto Stargate; Nvidia participou de rodadas de financiamento relacionadas ao projeto

4.3 OpenAI: o nó de maior concentração de compromissos

Conforme detalhado na Seção 3.3, a OpenAI mantém compromissos com sete fornecedores totalizando mais de US\$ 1,1 trilhão. O aspecto mais relevante para o mapeamento da teia é que praticamente todos esses fornecedores — Microsoft, Nvidia, Amazon — são também investidores diretos da companhia, e alguns (AMD) receberam instrumentos de capital (*warrants*) atrelados ao volume de compras de hardware. Esse desenho contratual significa que o crescimento da receita da OpenAI, o valor de suas ações não-listadas e a saúde financeira de seus fornecedores estão mecanicamente entrelaçados por cláusulas contratuais e não apenas por dinâmicas de mercado independentes.

4.4 Anthropic: de startup dependente da Amazon a hub de quatro hyperscalers

Diferentemente da configuração binária que caracterizava o ecossistema em 2024 (Microsoft–OpenAI de um lado, Amazon–Anthropic de outro), a Anthropic evoluiu para uma configuração de dependência múltipla e simultânea, com Amazon, Google, Microsoft e Nvidia atuando concomitantemente como investidores e fornecedores de infraestrutura, conforme detalhado na Seção 3.4. Do ponto de vista de risco sistêmico, essa diversificação de fornecedores reduz o risco idiossincrático de dependência de um único provedor de nuvem,

mas ao mesmo tempo aumenta o número de elos pelos quais um choque em qualquer uma dessas quatro companhias poderia se propagar para a Anthropic, e vice-versa.

4.5 Microsoft: o duplo-apostador

A Microsoft ocupa uma posição peculiar por manter, simultaneamente, uma participação econômica relevante na OpenAI (aproximadamente 27% do negócio com fins lucrativos, avaliado em torno de US\$ 135 bilhões) e um investimento direto na sua principal concorrente, a Anthropic. Adicionalmente, a Microsoft mantém direitos de revenda dos modelos da OpenAI através de 2032 no âmbito da parceria renegociada, e simultaneamente desenvolve modelos proprietários internos (MAI) através de sua divisão Microsoft AI, numa clara estratégia de diversificação para reduzir dependência de qualquer fornecedor único de modelos de fundação — ainda que sua exposição de *backlog* comercial à OpenAI seja estimada em cerca de 45% (aproximadamente US\$ 250 bilhões de um total de US\$ 627 bilhões em RPO).

4.6 Meta: o disruptor da narrativa de escassez

A Meta ocupa posição distinta das demais hyperscalers por não operar uma nuvem pública tradicional antes de 2026, direcionando historicamente seu capex para infraestrutura de uso interno (recomendação de conteúdo, publicidade, e mais recentemente treinamento de modelos Llama e Muse Spark). O anúncio da unidade *Meta Compute* em julho de 2026, detalhado nas Seções 1 e 9, representa uma mudança estratégica que a coloca em concorrência direta com AWS, Azure e Google Cloud, além de tensionar sua relação contratual com a CoreWeave — da qual é simultaneamente cliente (com compromissos da ordem de US\$ 35 bilhões acumulados até abril de 2026) e, potencialmente, futura concorrente.

4.7 Broadcom, AMD e a corrida por silício alternativo à Nvidia

Broadcom consolidou-se como o principal parceiro de *design* de silício customizado (ASICs) para hyperscalers e startups de fundação que buscam reduzir sua dependência da Nvidia, com compromissos relevantes junto à OpenAI (US\$ 350 bilhões) e à Anthropic/Google (aproximadamente 3,5 gigawatts de capacidade de TPU de próxima geração a partir de 2027). A AMD, por sua vez, consolidou uma posição de segunda fornecedora relevante de GPUs de uso geral, com compromisso de 6 gigawatts de aceleradores Instinct junto à OpenAI em troca de um *warrant* equivalente a até 10% do capital da AMD — um instrumento que, na prática, torna a AMD parcialmente dependente do sucesso financeiro futuro de seu próprio cliente.

4.8 SoftBank: o financiador cruzado com posição contraditória

A SoftBank ocupa uma posição financeira singular e reveladora dentro da teia. A companhia é, simultaneamente:

- Co-financiadora do Projeto Stargate (US\$ 500 bilhões) ao lado de OpenAI e Oracle;
- Co-líder da rodada de US\$ 122 bilhões que elevou a avaliação da OpenAI a US\$ 852 bilhões em março de 2026;
- **Vendedora integral de sua posição em ações da Nvidia**, uma liquidação de US\$ 5,8 bilhões anunciada em novembro de 2025 explicitamente destinada, segundo a própria companhia, a “financiar futuros investimentos em Inteligência Artificial”.

Essa combinação — aumentar exposição à OpenAI enquanto reduz a zero a exposição à Nvidia — foi interpretada por analistas de mercado (Matsui Securities, entre outros) como uma aposta concentrada e direcional na tese de que os retornos de deter a startup de fundação superarão os retornos de deter o fornecedor de hardware, ao mesmo tempo em que reduz a exposição da SoftBank a uma eventual correção nos múltiplos de avaliação de semicondutores. O mercado reagiu à notícia com uma queda de até 10% nas ações da própria SoftBank, refletindo desconforto dos investidores com a magnitude da aposta direcional.

4.9 Financiamento extrapatrimonial: a migração da dívida para veículos de propósito específico

Um desenvolvimento estrutural crucial, documentado de forma crescente ao longo do primeiro semestre de 2026, é a migração acelerada do financiamento de data centers para fora dos balanços patrimoniais das próprias hyperscalers, através de Veículos de Propósito Específico (SPVs) estruturados em parceria com gestoras de crédito privado.

Estrutura	Valor	Mecânica
Meta / Blue Owl ("Beignet Investor" / Hyperion, Louisiana)	US\$ 27–30 bi	Meta detém 20% do SPV; Blue Owl e investidores institucionais (PIMCO, BlackRock, Apollo) fornecem cerca de 90% via dívida sênior classificada A+ pela S&P; Meta oferece garantia de valor residual (RVG) de até US\$ 28 bi
Meta / SPV adicional (El Paso, Texas)	> US\$ 13 bi	Estrutura similar, sem âncora única; Morgan Stanley e JPMorgan atuam como estruturadores sem reter o risco
Oracle / Blue Owl & JPMorgan (Abilene, Texas — instalação OpenAI)	≈ US\$ 13 bi	US\$ 10 bi em dívida; SPV detém e arrenda de volta à Oracle
Oracle (Texas e Wisconsin)	US\$ 38 bi	Pacote de dívida para dois data centers adicionais
Oracle (Novo México)	US\$ 18 bi	Financiamento via empréstimo estruturado
xAI (SPV para GPUs Nvidia)	Até US\$ 12,5 bi	SPV compra GPUs e arrenda de volta à xAI, dentro de uma rodada total de US\$ 20 bi
Total migrado para fora do balanço (estimativa, ≈ 18 meses)	> US\$ 120 bi	Projeções de mercado (Morgan Stanley) apontam para até US\$ 800 bi adicionais em financiamento via crédito privado nos próximos dois anos

Sinal de Alerta 2. *O mecanismo do SPV permite que uma hyperscaler efetivamente tome emprestado dezenas de bilhões de dólares sem que a dívida subjacente apareça em seu balanço patrimonial consolidado — apenas a participação acionária minoritária no veículo e as obrigações de arrendamento operacional ficam registradas. No caso do SPV Beignet da Meta, a companhia mantém apenas 20% de participação acionária mas preserva controle operacional total ("controle sem consolidação"), mantendo cerca de US\$ 27 bilhões em dívida fora do balanço. Adicionalmente, a garantia de valor residual concedida pela Meta — um compromisso de até US\$ 28 bilhões caso o valor do data center caia abaixo de um patamar predeterminado ao final do contrato de arrendamento — transfere de volta à companhia o risco de obsolescência tecnológica, mas esse compromisso é descrito apenas em notas de rodapé do relatório anual, sem reconhecimento como passivo no balanço. Uma analogia histórica direta são as estruturas fora de balanço que precederam a crise financeira de 2008 e o colapso da Enron em 2001: nesses casos, o problema não foi a existência da estrutura em si, mas a opacidade sistêmica que ela introduziu, dificultando a avaliação de risco agregado por parte de reguladores e investidores até que as perdas já estivessem consolidadas.*

O mercado de crédito privado que financia essas estruturas cresceu de forma acentuada: de acordo com estimativas setoriais, o crédito privado destinado a companhias relacionadas a IA saltou de patamares próximos de zero para mais de US\$ 200 bilhões em poucos anos, com a Morgan Stanley projetando US\$ 800 bilhões adicionais em financiamento de data centers via esse canal nos próximos dois anos. Um estudo do Federal Reserve Bank of Chicago, divulgado em fevereiro de 2026, encontrou que a exposição direta dos bancos tradicionais a indústrias adjacentes à IA representa, em média, apenas 0,8% dos ativos totais — um número tranquilizador à primeira vista, mas que o próprio estudo qualifica ao alertar que os bancos "muito provavelmente possuem exposição adicional a indústrias adjacentes à IA através de linhas de crédito" a fundos de crédito privado, que por sua vez financiam diretamente os SPVs. Esse padrão de exposição indireta e em camadas dificulta a mensuração precisa do risco sistêmico agregado, ecoando preocupações regulatórias levantadas em ciclos de crédito anteriores.

4.10 Diagrama-síntese da teia de dependências

A tabela a seguir resume, de forma simplificada, os principais eixos de dependência mapeados nesta seção, classificando cada relação quanto à sua natureza predominante.

Origem	Destino	Natureza	Risco de contágio
Nvidia	OpenAI, Anthropic, xAI	Investimento + fornecimento de hardware	Alto: maior cliente único de GPUs de fronteira
Microsoft	OpenAI, Anthropic	Investimento + fornecimento de nuvem (ambos lados)	Alto: exposição de <i>backlog</i> de $\approx 45\%$ a um único cliente
Amazon	Anthropic	Investimento + nuvem primária + treinamento	Médio-alto: Anthropic é cliente-âncora do Trainium
Google	Anthropic, OpenAI (TPU)	Investimento + fornecimento de TPU	Médio: diversificação parcial via múltiplos clientes
Oracle	OpenAI	Fornecimento de nuvem financiado por dívida	Muito alto: $\approx 47\text{--}54\%$ do RPO em cliente único pré-lucro
SoftBank	OpenAI	Investimento direto + co-financiamento Stargate	Alto: aposta direcional após zerar posição em Nvidia
Blue Owl, PIMCO, BlackRock, Apollo	Meta, Oracle, xAI, CoreWeave	Crédito privado via SPV	Alto e opaco: risco disperso entre seguradoras e fundos de pensão
Meta	CoreWeave	Cliente e potencial concorrente simultâneo	Médio-alto: tensão contratual pós-anúncio Meta Compute

O padrão que emerge desse mapeamento é o de uma rede densamente interconectada, na qual um número relativamente pequeno de agentes — não mais que quinze a vinte companhias e fundos — concentra a esmagadora maioria dos fluxos financeiros do ciclo de IA, com múltiplos elos duplos (o mesmo agente sendo simultaneamente credor e devedor, investidor e cliente, fornecedor e concorrente) que reduzem a diversificação efetiva do risco sistêmico, mesmo quando cada relação bilateral parece, isoladamente, razoável do ponto de vista de seus participantes diretos.

5 Limitações Físicas: Silício e Energia como Tetos Rígidos de Expansão

5.1 Do gargalo de chips ao gargalo de energia

A visão convencional que prevaleceu entre 2022 e 2024 identificava a disponibilidade de GPUs de ponta como o principal fator limitante da expansão da capacidade computacional de IA. Ao longo de 2025 e 2026, contudo, esse gargalo deslocou-se progressivamente para a disponibilidade de energia elétrica, conexão à rede e capacidade de resfriamento — fatores com ciclos de maturação estruturalmente mais longos e menos elásticos do que a manufatura de semicondutores.

Observação 3. *Um rack moderno de GPUs Blackwell da Nvidia opera com densidade de potência de aproximadamente 140 kW, com 72 GPUs por rack. Um data center de 100 MW com eficiência de uso de energia (PUE) de aproximadamente 1,1 comporta cerca de 650 desses racks — aproximadamente 47.000 GPUs B200. Escalar para as centenas de gigawatts de capacidade comprometida contratualmente pelo ecossistema (10 GW apenas no compromisso Nvidia–OpenAI, mais 10 GW no compromisso Broadcom–OpenAI, mais 6 GW no compromisso AMD–OpenAI) exigiria uma expansão de geração elétrica dedicada comparável, em ordem de grandeza, à capacidade instalada de países de porte médio.*

5.2 A corrida por energia nuclear e reatores modulares

Diante da limitação de capacidade da rede elétrica convencional e dos longos prazos de licenciamento para novas linhas de transmissão, as hyperscalers passaram a buscar fontes de geração dedicada, com destaque para acordos de energia nuclear:

Empresa	Compromissos de energia nuclear
Microsoft	Acordo de 20 anos com a Constellation Energy para reativação da usina de Three Mile Island, apoiado por empréstimo de US\$ 1 bilhão do governo americano; acordo adicional de 20 anos para energia da usina de Clinton (Illinois) a partir de 2027
Meta	Acordos com Vistra, TerraPower e Oklo para até 6,6 gigawatts de capacidade nuclear até 2035; acordo de 20 anos com a Constellation para a usina de Clinton
Amazon	Acordos para 1,9 gigawatt de energia nuclear da usina de Susquehanna, além de parcerias para o desenvolvimento de reatores modulares de pequeno porte (SMR)
Nvidia & Microsoft	Parceria anunciada em março de 2026 com a TerraPower, que projeta atingir até 5 gigawatts de capacidade via SMR até meados da década de 2030

Sinal de Alerta 3. *Existe um descasamento temporal estrutural entre o ciclo de investimento em energia nuclear e o ciclo de obsolescência de hardware de IA. Projetos de reatores modulares de pequeno porte (SMR) requerem, de acordo com análises do Carnegie Endowment for International Peace e de consultorias especializadas do setor, entre cinco e dez anos desde o licenciamento até a operação comercial — e, até o momento, nenhum projeto de SMR opera em escala comercial nos Estados Unidos. Mesmo a reativação de usinas nucleares convencionais pré-existentes exige revisão regulatória plurianual. Esse horizonte é fundamentalmente incompatível com o ciclo de dezoito a trinta e seis meses de renovação de gerações de GPU: a energia nuclear contratada hoje pode não estar disponível antes que a geração de chips para a qual foi originalmente planejada já tenha sido substituída por arquiteturas sucessoras (a Nvidia já sinaliza a chegada da plataforma Vera Rubin ainda em 2026, sucessora do Blackwell).*

Diante desse descasamento, o caminho mais rápido de geração dedicada tem sido turbinas a gás natural, implementáveis em doze a dezoito meses — mas que carregam custos ambientais, políticos e de licenciamento de emissões atmosféricas próprios, além de exposição direta à volatilidade do preço do gás natural discutida na Seção 6 no contexto do choque de energia do Oriente Médio.

5.3 Oposição comunitária e restrições regulatórias locais

A expansão acelerada de data centers gerou fricção crescente com comunidades locais nos Estados Unidos, manifestada em moratórias estaduais e municipais, disputas sobre uso de água para resfriamento e aumento de tarifas de energia repassado a consumidores residenciais nas proximidades de grandes instalações. Esse fator, ainda que menos discutido nas análises financeiras convencionais, constitui um risco de execução relevante: sites que dependiam de cronogramas de conexão à rede ou de aprovação de infraestrutura de geração podem sofrer atrasos que comprometem os prazos contratuais assumidos junto a clientes como a OpenAI, cujos contratos preveem capacidade operacional em janelas temporais específicas a partir de 2027.

5.4 Prêmio de certeza energética e nova geografia dos data centers

A escassez de energia certa e disponível tornou-se, segundo relatos do setor imobiliário corporativo, o principal diferencial na escolha de localização de novos data centers, com sites que oferecem energia nuclear ou geração dedicada comandando prêmios de aluguel de 15% a 25% sobre alternativas comparáveis conectadas apenas à rede convencional. Estados como Texas, Louisiana e Virgínia competem ativamente como jurisdições preferenciais para infraestrutura de IA, com o fator decisivo migrando de disponibilidade de terreno e incentivos fiscais para velocidade de licenciamento e disponibilidade energética.

5.5 Implicação para a tese de investimento

A conjunção de restrições físicas de energia, prazos de maturação de projetos nucleares incompatíveis com o ciclo de obsolescência de chips, e oposição comunitária crescente sugere que a capacidade efetivamente entregável nos próximos dois a três anos pode ficar substancialmente aquém dos gigawatts comprometidos contratualmente pelo ecossistema. Esse descompasso entre capacidade contratada e capacidade fisicamente entregável constitui um vetor de risco adicional e específico: mesmo que a demanda por serviços de IA continue crescendo, atrasos na disponibilização de energia podem forçar renegociação de contratos, penalidades e reconhecimento de receita mais lento do que o originalmente projetado pelos provedores de infraestrutura.

6 Panorama Macroeconômico Global e Perspectivas de Juros

6.1 Por que a conjuntura macro importa para a tese de bolha em IA

Um erro analítico comum em teses de bolha setorial é tratar a dinâmica de valuation como um fenômeno isolado, determinado exclusivamente por fatores idiossincráticos do setor em questão. Na prática, ciclos de excesso especulativo historicamente se rompem — ou, alternativamente, se prolongam — em função das condições de liquidez e do custo de capital vigentes na economia mais ampla. O ano de 2026 apresenta uma particularidade rara: um choque geopolítico e energético originado fora do setor de tecnologia, mas com potencial de alterar materialmente o custo de capital que sustenta o ciclo de investimento em IA precisamente no momento em que esse ciclo mais depende de financiamento externo barato.

6.2 O choque de energia do conflito no Oriente Médio

Em fevereiro de 2026, teve início um conflito armado envolvendo Irã, Israel e Estados Unidos que a Agência Internacional de Energia (AIE) classificou como responsável pela “maior disrupção de oferta da história do mercado global de petróleo”. O fechamento parcial do Estreito de Ormuz — por onde transitam normalmente cerca de 20% da oferta mundial de petróleo e parcela relevante do gás natural liquefeito destinado à Ásia — provocou uma escalada de preços sem precedentes recentes:

- O petróleo Brent, negociado a cerca de US\$ 71–72 por barril antes do início do conflito (27 de fevereiro de 2026), subiu para a faixa de US\$ 80–82 já nos primeiros dias, atingindo picos próximos de **US\$ 120 por barril** em março — uma alta acumulada superior a 55% desde o início das hostilidades, com o próprio mês de março registrando um dos maiores saltos mensais já observados (+51%);
- Cessar-fogos sucessivos, frágeis e repetidamente renegociados entre abril e junho de 2026 permitiram recuos parciais dos preços, com o Brent oscilando na faixa de US\$ 85–95 por barril ao longo do segundo trimestre — ainda substancialmente acima dos níveis pré-conflito;
- Investigações da *Financial Times* identificaram padrões de negociação suspeitos — apostas bilionárias em queda do petróleo poucos minutos antes de anúncios políticos relevantes — levantando questionamentos sobre uso de informação privilegiada em torno dos anúncios de cessar-fogo;
- O tráfego de navios pelo Estreito de Ormuz permaneceu, mesmo após os acordos de cessar-fogo, muito abaixo dos níveis anteriores ao conflito, sugerindo que a normalização completa da oferta de energia do Golfo Pérsico é um processo mais lento do que a simples cessação das hostilidades.

Observação 4. A Agência Internacional de Energia descreveu a situação como “o maior desafio de segurança energética global da história”, traçando um paralelo direto com os choques do petróleo da década de 1970. O investimento global em energia projetado para 2026 (US\$ 3,4 trilhões) já reflete essa reorientação: investimento em petróleo caindo pelo terceiro ano consecutivo para abaixo de US\$ 500 bilhões, enquanto o investimento em gás natural sobe para US\$ 330 bilhões (máxima em uma década) e o investimento em carvão atinge o maior patamar desde 2012 — uma reversão parcial da trajetória de transição energética que precedia o conflito.

6.3 Estados Unidos: o giro hawkish do Federal Reserve

O choque de energia coincidiu com uma mudança de liderança no Federal Reserve: Kevin Warsh assumiu a presidência em 15 de maio de 2026, sucedendo Jerome Powell. Sob sua condução, o Comitê Federal de Mercado Aberto (FOMC) manteve a taxa de juros na faixa de 3,50%–3,75% em sua reunião de 17 de junho de 2026 — mas a mensagem embutida nas projeções foi marcadamente mais restritiva do que o esperado:

Indicador	Projeção março/2026	Projeção junho/2026	Direção
Taxa de juros mediana (fim de 2026)	3,4%	3,8%	Alta
Inflação PCE headline (2026)	2,7%	3,6%	Alta acentuada
Inflação PCE núcleo (2026)	—	3,3%	Alta

A decisão de manutenção da taxa foi unânime (12 a 0) — mas 17 dos 18 dirigentes que submeteram projeções passaram a considerar que os riscos para a inflação estão inclinados para cima, uma inversão em relação à postura predominante no início do ano, quando o mercado ainda precificava um a dois cortes de juros ao

longo de 2026. O núcleo do índice de Gastos com Consumo Pessoal (PCE) subiu de 3,0% em dezembro de 2025 para 3,3% em abril de 2026, refletindo a passagem do choque de energia para preços mais amplos da economia.

Sinal de Alerta 4. *Um ambiente de juros mais altos por mais tempo (higher for longer) eleva mecanicamente o custo de capital de toda a economia — mas atinge com particular severidade setores que dependem de financiamento externo intensivo para sustentar crescimento antecipado de receita, como é o caso do ecossistema de infraestrutura de IA. O aumento do custo de dívida corporativa e de crédito privado, discutido na Seção 4.8, encarece diretamente as estruturas de SPV que financiam grande parte da expansão de data centers, ao mesmo tempo em que reduz o valor presente de fluxos de caixa futuros incertos — exatamente o tipo de ativo que domina os balanços das startups de fundação e de parte relevante das próprias hyperscalers.*

6.4 Zona do euro: primeira alta de juros do Banco Central Europeu desde 2023

O Banco Central Europeu (BCE) elevou suas três taxas de juros de referência em 25 pontos-base em 11 de junho de 2026 — a primeira alta desde 2023 — levando a taxa de depósito a 2,25%. A decisão refletiu diretamente a pressão inflacionária do mesmo choque de energia: a inflação da zona do euro acelerou para 3,2% em maio de 2026, bem acima da meta de 2%, com a inflação de energia subindo 10,9% ano contra ano. As novas projeções do BCE apontam para inflação média de 3,0% em 2026 (revisão para cima frente aos 2,6% projetados anteriormente) e crescimento do PIB revisado para baixo, de 0,9% para 0,8% em 2026 — uma combinação de inflação mais alta e crescimento mais fraco que caracteriza um ambiente de estagflação moderada. A presidente do BCE, Christine Lagarde, e a equipe técnica da instituição destacaram que a magnitude dos efeitos de segunda ordem sobre salários e preços de serviços dependerá crucialmente da duração e intensidade do conflito no Oriente Médio, com cenários alternativos do próprio banco central apontando para deterioração adicional em um cenário mais severo.

6.5 China: crescimento resiliente na superfície, fragilidades estruturais na base

A economia chinesa registrou crescimento de 5,0% no primeiro trimestre de 2026, superando o consenso de mercado (4,6%) e acelerando frente aos 4,5% do quarto trimestre de 2025 — um resultado, contudo, inflado por uma onda de exportações antecipadas para o sudeste asiático e o Oriente Médio, à frente da plena entrada em vigor do regime de tarifas americanas de 145% sobre produtos chineses. Sob a superfície desse número, persistem fragilidades estruturais bem documentadas:

- O setor imobiliário permanece em sua quinta fase consecutiva de contração, com novos lançamentos, vendas e investimento em construção entre 50% e 80% abaixo dos picos de 2020–2021;
- A China enfrenta pressão deflacionária persistente desde 2022, com o índice de preços ao produtor negativo por mais de três anos consecutivos — um padrão sem precedente histórico direto de uma economia reportando 5% de crescimento real em meio a deflação prolongada;
- Organismos internacionais (FMI, Banco Mundial, Goldman Sachs) projetam crescimento na faixa de 4,0% a 4,8% para 2026, com desaceleração adicional para os anos seguintes à medida que o impulso das exportações antecipadas se dissipa;
- O choque inflacionário derivado do conflito no Oriente Médio introduziu uma dinâmica atípica para a China: pela primeira vez em anos, a inflação ao consumidor e ao produtor subiu (1,0% e 0,5% em março, respectivamente) — mas impulsionada por um choque de custos externos, e não por uma recuperação orgânica da demanda doméstica, o que comprime ainda mais as margens de produtores incapazes de repassar integralmente os aumentos de custo aos consumidores.

O elo direto entre a China e a tese de bolha em IA

Analistas da UBS explicitamente incorporam a possibilidade de um estouro da bolha de IA como um dos principais fatores de risco para a economia chinesa em seus cenários para 2026–2027, reconhecendo que uma desaceleração abrupta do investimento ocidental em infraestrutura de IA reduziria a demanda por semicondutores, componentes eletrônicos e equipamentos de manufatura avançada — áreas em que a China vem registrando crescimento acelerado de exportações como parte de sua estratégia de reposicionamento industrial pós-crise imobiliária.

6.6 Mercados emergentes e economias exportadoras de energia

O choque de petróleo produziu efeitos assimétricos entre mercados emergentes: economias importadoras líquidas de energia (Índia, Paquistão, Bangladesh, a maior parte do sudeste asiático) enfrentaram pressão inflacionária e de balanço de pagamentos, enquanto exportadores de energia fora do eixo do conflito (parte

da América Latina, alguns produtores africanos) capturaram ganhos de termos de troca. O Conselho de Cooperação do Golfo, por sua vez, sofreu o que analistas descreveram como um colapso sistêmico de seu modelo econômico regional, dado o grau de dependência direta das exportações de petróleo e gás através do Estreito de Ormuz. Paralelos históricos com os choques do petróleo de 1973 e 1979 sugerem a possibilidade de fluxos de capital “*petrodólar*” direcionados a ativos reais internacionais — incluindo imóveis de alto padrão em centros financeiros como Londres — ainda que a magnitude desse efeito no ciclo atual permaneça incerta e dependente da duração do conflito.

6.7 Síntese: a convergência de dois ciclos independentes

O aspecto mais relevante desta seção para a tese central do relatório é a constatação de que o ciclo de aperto monetário sincronizado entre Estados Unidos e zona do euro em 2026 tem origem fundamentalmente *alheia* à dinâmica do setor de IA — decorre de um choque geopolítico de oferta de energia, não de um aquecimento da demanda agregada ligado ao boom de investimento em infraestrutura computacional. Essa distinção importa porque significa que o endurecimento das condições financeiras não é uma resposta orgânica do sistema ao excesso do próprio setor de IA, e portanto não deve ser interpretado como um mecanismo de autocorreção do mercado. Trata-se, em vez disso, de um choque exógeno que reduz a margem de segurança de um setor já estruturalmente dependente de financiamento externo abundante e barato — uma coincidência de dois ciclos historicamente distintos (choque de oferta de energia geopolítico e ciclo de sobre-investimento em infraestrutura tecnológica) que, se ambos persistirem, tende a amplificar reciprocamente seus efeitos sobre a economia real e sobre os mercados financeiros.

7 Auditoria do Fluxo de Capital dos Grandes Agentes de Mercado

7.1 A pergunta central: compra genuína ou posicionamento defensivo sob preços inflados?

Um dos exercícios mais informativos para avaliar a maturidade de um ciclo especulativo é examinar não o que os participantes do mercado dizem publicamente, mas o que revelam através de suas próprias transações — compra e venda de ações, opções, e mudanças de alocação em fundos soberanos e institucionais. Esta seção consolida evidências de quatro categorias distintas de agentes: (i) executivos e *insiders* das próprias companhias de tecnologia; (ii) investidores individuais de alto perfil com histórico de acerto em ciclos anteriores; (iii) conglomerados e fundos com posições estratégicas de grande porte; e (iv) gestores passivos e fundos soberanos, cuja exposição é majoritariamente estrutural e não discricionária.

7.2 Venda recorde de ações por executivos e *insiders* (2025)

Segundo análise da Bloomberg sobre dados de negociação de *insiders*, executivos, fundadores e conselheiros de grandes companhias de tecnologia venderam, em conjunto, mais de **US\$ 16 bilhões em ações ao longo de 2025** — um recorde recente.

Executivo	Companhia	Valor vendido	Contexto
Jeff Bezos	Amazon	US\$ 5,7 bi	25 milhões de ações; coincidiu com casamento de alto perfil; via plano 10b5-1 pré-estabelecido
Safra Catz	Oracle	US\$ 2,5 bi	12,5 milhões de ações; exercício de opções após deixar o cargo de CEO
Michael Dell	Dell Technologies	US\$ 2,2 bi	Mais de 16,2 milhões de ações
Jensen Huang	Nvidia	US\$ 1,0 bi	Coincidiu com a companhia atingindo US\$ 5 tri de valor de mercado
Jayshree Ullal	Arista Networks	≈ US\$ 1,0 bi	CEO de fornecedora de equipamentos de rede de alta velocidade
Mark Zuckerberg	Meta	US\$ 945 mi	Roteado através de fundação filantrópica (Chan Zuckerberg Initiative)
Nikesh Arora	Palo Alto Networks	> US\$ 700–740 mi	Padrão mensal contínuo de exercício e venda via plano 10b5-1
Baiju Bhatt	Robinhood	> US\$ 700 mi	Cofundador
Frank Sloatman	Snowflake	US\$ 758 mi	Presidente do conselho, ex-CEO

Observação 5. *A maior parte dessas vendas foi executada através de planos de negociação pré-estabelecidos (10b5-1 trading plans), registrados junto a reguladores antes da valorização das ações — o que tecnicamente afasta qualquer indício de uso de informação privilegiada, mas não altera o fato revelador subjacente: a decisão original de estabelecer esses planos de venda sistemática foi tomada por agentes com acesso privilegiado à trajetória interna de crescimento e de custos de suas próprias companhias, precisamente no período de maior valorização do ciclo de IA. O padrão — venda ampla e quase unânime, e não compra — é o dado relevante, independentemente da defesa jurídica legítima de cada transação individual.*

7.3 Michael Burry: da posição vendida à tese pública sobre depreciação

Conforme já introduzido nas Seções 1 e 2, o investidor Michael Burry — gestor do fundo Scion Asset Management, célebre por ter identificado a bolha imobiliária americana antes da crise de 2008 — consolidou, ao longo do terceiro trimestre de 2025 e ao longo de 2026, uma das posições vendidas mais visíveis do ciclo atual:

- Divulgação inicial (13F de setembro de 2025): opções de venda (*puts*) sobre aproximadamente 5 milhões de ações da Palantir (valor nominal de US\$ 912 milhões) e 1 milhão de ações da Nvidia (valor nominal de US\$ 187 milhões), representando até 80% do portfólio do fundo em posições *bearish*;
- Expansão ao longo de 2026: novas posições vendidas sobre o ETF de semicondutores SOXX, o ETF Nasdaq-100 (QQQ) e a Oracle, além de manutenção e rolagem das posições em Nvidia (*strikes* de US\$ 110–115, vencimentos entre dezembro de 2026 e junho de 2027) e Palantir (*strikes* de US\$ 50–100);
- Rotação simultânea para posições compradas em ações de *software* tradicional considerado excessivamente penalizado pelo entusiasmo com IA — Adobe, Autodesk, Salesforce e Veeva Systems;
- Publicação, em novembro de 2025, da tese de que hyperscalers estariam subestimando a depreciação de GPUs em cerca de US\$ 176 bilhões entre 2026 e 2028 (detalhada na Seção 2.6), classificando a prática como “uma das fraudes mais comuns da era moderna”;
- Resultados parciais até meados de 2026: a posição em Palantir mostrou-se lucrativa, com a ação recuando cerca de 35% desde a entrada da posição (incluindo uma queda de 51% na Oracle desde o

pico do terceiro trimestre de 2025), enquanto a posição em Nvidia permaneceu run majoritariamente no prejuízo, com a ação negociando de forma lateralizada.

Interpretação equilibrada da posição de Burry

É importante notar, para uma análise equilibrada, que nem todas as posições de Burry se mostraram lucrativas até a data deste relatório — a posição em Nvidia especificamente permanece *underwater*. O próprio Burry reconheceu publicamente ter mantido posições erroneamente pessimistas em ciclos anteriores. A relevância de sua posição para esta tese de investimento não reside na certeza de que suas apostas se provarão corretas, mas no fato de que um investidor com histórico público de identificação bem-sucedida de bolhas de crédito optou por alocar até 80% de seu portfólio contra o consenso predominante do mercado — um sinal qualitativo de dissenso relevante, ainda que não uma previsão garantida.

7.4 Peter Thiel: liquidação integral da posição em Nvidia

Entre julho e setembro de 2025, o fundo Thiel Macro LLC — veículo de investimento pessoal do bilionário Peter Thiel, cofundador do PayPal e da Palantir — vendeu a totalidade de sua posição em ações da Nvidia: 537.742 ações, avaliadas em mais de US\$ 100 milhões e correspondentes a aproximadamente 40% do portfólio total do fundo até então. Simultaneamente, o fundo redirecionou capital para posições em Apple e Microsoft, reduzindo sua exposição total a ações americanas de US\$ 212 milhões para US\$ 74 milhões — um recuo de mais da metade da exposição total à renda variável. A publicação dessa movimentação, em novembro de 2025, provocou queda superior a 2% nas ações da Nvidia no mesmo pregão. Analistas interpretaram a decisão como uma aposta relativa de que plataformas que integram IA a produtos de consumo final (Apple, Microsoft) ofereceriam retornos mais duráveis do que o fornecedor de hardware da infraestrutura subjacente.

7.5 SoftBank: a liquidação de US\$ 5,8 bilhões que precedeu a de Thiel

Uma semana antes da divulgação da posição de Thiel, a SoftBank Group revelou ter vendido a totalidade de sua posição em ações da Nvidia — uma participação avaliada em US\$ 5,8 bilhões — declarando explicitamente que o capital seria redirecionado para “financiar futuros investimentos em Inteligência Artificial”, principalmente sua posição na OpenAI. A notícia provocou queda de até 10% nas próprias ações da SoftBank, refletindo o desconforto do mercado com a magnitude e a direção da realocação, mais do que com a mera liquidação em si. Como discutido na Seção 4.7, essa combinação de reduzir a zero a exposição à Nvidia enquanto se amplia agressivamente a exposição à OpenAI configura uma aposta direcional concentrada, e não uma simples diversificação defensiva.

7.6 Concentração em índices passivos: risco estrutural não discricionário

Diferentemente das categorias anteriores — que refletem decisões ativas e discricionárias de venda — a exposição de fundos passivos ao ciclo de IA é estrutural e mecânica, decorrente da metodologia de ponderação por capitalização de mercado utilizada pelo índice S&P 500 e por fundos que o replicam (incluindo os maiores gestores de ativos do mundo, como BlackRock, com mais de US\$ 14 trilhões sob gestão, e Vanguard, com aproximadamente US\$ 12 trilhões).

Métrica de concentração (junho de 2026)	Valor	Comparação histórica
Peso das “Magnificent Seven” no S&P 500	≈ 33–34%	Pico do índice
Peso das 10 maiores empresas no S&P 500	> 40%	Supera o pico da bolha <i>dot-com</i> de 2000 (≈ 27%, segundo Goldman Sachs)
Peso das 10 maiores empresas no S&P 500 (média histórica)	≈ 24%	Nível de referência de longo prazo
Participação da Magnificent Seven no lucro econômico do S&P 500	≈ 70% (Russell Investments)	Concentração de lucros compatível com a concentração de valor de mercado

Sinal de Alerta 5. *Um investidor que aloca capital em um fundo indexado ao S&P 500 — historicamente vendido como veículo de diversificação ampla — está hoje destinando mais de 40 centavos de cada dólar investido a apenas dez companhias, a maioria delas diretamente exposta ao ciclo de investimento em infraestrutura*

de IA. Esse grau de concentração, superior ao observado no pico da bolha dot-com de 2000, transforma a exposição de investidores passivos — incluindo fundos de pensão, planos de aposentadoria e investidores de varejo que acreditam estar diversificados — em uma aposta concentrada e involuntária no desfecho do ciclo de IA, independentemente de sua tolerância a risco individual ou de terem tomado essa decisão de forma consciente.

No início de junho de 2026, esse risco de concentração se materializou de forma concreta: as ações da Magnificent Seven perderam, em conjunto, cerca de US\$ 2 trilhões em valor de mercado ao longo de poucas semanas, arrastando o índice mais amplo para baixo mesmo com a maioria das demais 493 companhias do S&P 500 operando em território positivo — evidência empírica direta de como a concentração extrema amplifica, em vez de diluir, o risco idiossincrático de um punhado de empresas para toda a poupança de longo prazo de milhões de investidores passivos.

7.7 Fundos soberanos: postura predominantemente favorável, com uso instrumental da própria tecnologia

Ao contrário do padrão de venda líquida observado entre *insiders* e alguns hedge funds direcionais, os maiores fundos soberanos do mundo mantiveram, até a data deste relatório, postura predominantemente favorável ao ciclo de IA — tanto como investidores em ações de tecnologia quanto como adotantes da própria tecnologia em seus processos internos. O Fundo de Pensão Global do Governo da Noruega (Government Pension Fund Global), maior fundo soberano do mundo com patrimônio superior a US\$ 2,2 trilhões e participação em cerca de 1,5% de todas as ações listadas globalmente, reportou retorno anual de 15,1% impulsionado por ganhos em ações globais de tecnologia, e passou a utilizar modelos de linguagem (incluindo o Claude, da Anthropic) para triagem de risco em seu processo de investimento. Esse padrão sugere que, ao menos entre os alocadores de capital soberano de mais longo prazo, a tese de bolha ainda não se traduziu em uma mudança de postura estratégica — uma divergência notável frente ao comportamento de venda mais agressivo observado entre *insiders* corporativos e hedge funds direcionais especializados.

7.8 Síntese: um mercado de sinais mistos, mas com viés de cautela crescente entre os mais informados

A convergência das evidências apresentadas nesta seção sugere um quadro de sinais mistos, porém com uma assimetria informativa relevante: os agentes com maior proximidade operacional e informacional direta às companhias — executivos, fundadores e *insiders* — venderam de forma ampla e quase unânime ao longo de 2025, enquanto investidores especializados em identificar excessos de crédito e de valuation (Burry, Thiel, SoftBank em relação à Nvidia especificamente) assumiram posições explicitamente defensivas ou vendidas. Já os grandes alocadores de capital de longuíssimo prazo, como fundos soberanos e fundos de índice passivo, mantiveram exposição elevada — ainda que, no caso dos fundos passivos, essa exposição seja em grande parte estrutural e não resultado de uma escolha ativa e informada de aumentar risco. Essa divergência entre os agentes mais próximos da informação operacional e os agentes de alocação mais ampla e estrutural constitui, por si só, um dado relevante para qualquer investidor que avalie o grau de maturidade — e de risco — do ciclo atual.

8 O Que É Factível e o Que É Excesso: Separando Sinal de Ruído

8.1 Princípio metodológico desta seção

Uma tese de bolha bem construída não afirma que a tecnologia subjacente carece de valor — afirma que o *preço* e o *ritmo de investimento* atribuídos a essa tecnologia excedem, em determinado momento, a capacidade demonstrada de geração de retorno. Esta seção separa deliberadamente três categorias de evidência: (i) o que já está comprovado por dados de receita e produtividade; (ii) o que permanece genuinamente incerto e dependente de execução futura; e (iii) o que constitui, com base nas evidências disponíveis em julho de 2026, excesso especulativo desconectado de fundamentos observáveis.

8.2 O que é factível: evidências de valor econômico real

- **Crescimento de receita genuíno e verificável em startups de fundação.** A trajetória de receita da Anthropic — de aproximadamente US\$ 1 bilhão no início de 2025 para US\$ 45–47 bilhões em maio de 2026 — representa uma das curvas de crescimento mais rápidas já documentadas por qualquer empresa de tecnologia, superando inclusive o ritmo histórico de crescimento de receita de gigantes como a Salesforce. Ainda que parte dessa receita inclua componentes de compromissos de investimento

cruzado (Seção 4), a base de mais de 500 clientes corporativos pagando acima de US\$ 1 milhão anual, incluindo oito das dez maiores empresas do Fortune 10, representa demanda genuína e verificável por produtos de IA aplicados a fluxos de trabalho corporativos.

- **Adoção mensurável de ferramentas de codificação assistida por IA.** Relatos de adoção corporativa — como o caso da Uber, cuja adoção da ferramenta Claude Code saltou de 32% para 84% de sua base de 5.000 engenheiros em poucos meses — demonstram utilidade prática genuína em casos de uso técnicos específicos, ainda que os custos operacionais associados (entre US\$ 500 e US\$ 2.000 mensais por engenheiro, em alguns casos) estejam gerando pressão orçamentária inesperada sobre departamentos de tecnologia corporativos.
- **Retorno sobre investimento comprovado em automação de retaguarda (*back-office*).** Seguindo o estudo do Projeto NANDA do MIT (*The GenAI Divide: State of AI in Business 2025*), ainda que a maioria dos projetos-piloto de IA generativa não produza impacto mensurável de lucro, os casos de sucesso concentram-se de forma consistente em automação de processos de retaguarda — eliminação de terceirização de processos de negócio, redução de custos de agências externas e otimização de operações internas — e não nas áreas de vendas e marketing, para onde a maior parte do orçamento corporativo de IA generativa tem sido historicamente direcionada.
- **Redução de custo por token e ganhos de eficiência de inferência.** A introdução de arquiteturas de silício customizado (TPUs do Google, Trainium da Amazon, MTIA da Meta, MAIA da Microsoft) e de modelos otimizados para custo (como o Gemini 3.5 Flash do Google) demonstra progresso técnico real na redução do custo marginal de inferência — um dos requisitos estruturais, discutidos na Seção 2, para que o modelo de negócio de IA se aproxime da economia unitária de software tradicional.

8.3 O que permanece genuinamente incerto

- **A proporção real de pilotos de IA corporativa que geram retorno mensurável.** O próprio estudo do MIT que popularizou a estatística de “95% de fracasso” foi objeto de críticas metodológicas relevantes — baseou-se em apenas 52 entrevistas qualitativas, adotou uma janela de mensuração de apenas seis meses pós-piloto, e não incorporou métricas de valor mais amplas como ganhos de eficiência, redução de rotatividade de clientes ou velocidade de conversão de vendas. Simultaneamente, estudos subsequentes (Boston Consulting Group, Gartner, S&P Global) convergem para estimativas de sucesso mensurável entre 20% e 30% dos projetos — números mais otimistas do que o titular original, mas ainda distantes de validar o volume agregado de investimento em curso.
- **A trajetória de conversão do *backlog* contratual em receita reconhecida.** O caso da Oracle, detalhado na Seção 3.5, ilustra como uma carteira de compromissos contratuais nominalmente elevada (US\$ 638 bilhões) pode se converter em receita efetiva a um ritmo muito mais lento (apenas cerca de 12% nos primeiros doze meses) do que o mercado inicialmente precificou, especialmente quando a concentração em um único cliente pré-lucro (OpenAI) introduz risco de execução que se materializa apenas gradualmente.
- **O momento e o valor de eventuais aberturas de capital (IPOs) da OpenAI e da Anthropic.** Ambas as companhias sinalizaram intenção de abrir capital, com avaliações privadas recentes na casa de US\$ 850 bilhões a quase US\$ 1 trilhão. A capacidade desses eventos de liquidez se concretizarem nos prazos e valores esperados — e de resistirem ao escrutínio trimestral de investidores públicos, tipicamente menos tolerante a prejuízos operacionais persistentes do que investidores de capital de risco privado — permanece uma incógnita relevante para toda a cadeia de fornecedores que depende dessas duas companhias como clientes-âncora.
- **A duração e a intensidade do choque de energia do Oriente Médio.** Conforme discutido na Seção 6, o desfecho do conflito no Estreito de Ormuz permanece incerto, com cenários que vão da normalização gradual da oferta de petróleo até uma escalada renovada — ambos os desfechos com implicações diretas e materialmente distintas sobre o custo de capital que sustenta o ciclo de infraestrutura de IA.

8.4 O que constitui excesso especulativo

- **Extrapolação linear de curvas de crescimento de receita de quinze meses para horizontes de cinco a dez anos.** Compromissos contratuais como os da OpenAI (US\$ 1,1 trilhão distribuídos até 2035) pressupõem uma trajetória de crescimento de receita e de eficiência de custo sustentada por um período muito mais longo do que qualquer histórico observável até o momento — a companhia projeta não atingir fluxo de caixa positivo antes de 2030, um horizonte de sete a oito anos de queima de caixa

continuada financiada por rodadas sucessivas de capital externo.

- **Financiamento circular mascarando a origem da demanda declarada.** Conforme mapeado exaustivamente na Seção 4, uma parcela não quantificável — mas estruturalmente relevante — do crescimento de receita e de compromissos contratuais anunciados publicamente pelo ecossistema resulta de acordos em que o próprio fornecedor de capital ou de hardware é also, simultaneamente, cliente ou beneficiário direto do contrato. Isso não invalida a totalidade da demanda, mas dificulta severamente a tarefa de discernir qual fração do crescimento reportado reflete uso genuíno e independente da tecnologia por clientes finais, versus reciclagem de capital entre um número reduzido de agentes interligados.
- **Migração de risco de crédito para veículos extrapatrimoniais opacos.** A migração de mais de US\$ 120 bilhões em financiamento de data centers para SPVs, com projeções de centenas de bilhões adicionais, reproduz um padrão estrutural — opacidade de risco disperso entre múltiplas camadas de intermediários financeiros — que precedeu crises de crédito anteriores, independentemente do mérito técnico ou econômico de cada projeto individual de data center financiado dessa forma.
- **Premissas de depreciação contábil sistematicamente mais longas do que o ciclo real de obsolescência tecnológica declarado pelo próprio fornecedor de hardware.** Conforme detalhado na Seção 2.6, a disputa pública sobre prazos de depreciação de GPUs constitui, no mínimo, um indicador de que parte relevante dos lucros correntemente reportados pelo setor pode estar apoiada em premissas contábeis favoráveis e não uniformemente auditadas, mesmo sem que se resolva definitivamente qual das partes está tecnicamente correta.
- **Concentração de mercado incompatível com diversificação de risco genuína.** A concentração de mais de um terço do índice S&P 500 em sete companhias diretamente expostas ao ciclo de IA, superando o pico da bolha *dot-com* de 2000, representa um nível de concentração que, independentemente do mérito individual de cada uma dessas companhias, elimina estruturalmente a proteção de diversificação que investidores passivos presumem estar obtendo.

Síntese da Seção 8

A leitura mais equilibrada das evidências disponíveis sugere que a tecnologia de Inteligência Artificial generativa já produziu, e continuará produzindo, valor econômico genuíno e mensurável em nichos específicos de aplicação — particularmente automação de retaguarda, ferramentas de codificação assistida e alguns fluxos de trabalho corporativos verticalizados. O problema identificado por esta tese de investimento não reside na existência desse valor, mas na desproporção entre o ritmo e o volume do investimento em infraestrutura física comprometido contratualmente (capex de US\$ 700+ bilhões anuais, compromissos de US\$ 1+ trilhão por startup individual) e a velocidade, ainda incerta, de conversão desse investimento em fluxo de caixa recorrente e sustentável na ponta final da cadeia de valor.

9 Vetores de Ruptura e Gatilhos de Contágio

9.1 Tipologia dos gatilhos potenciais

Com base no mapeamento de dependências da Seção 4 e na anatomia contábil da Seção 2, é possível classificar os vetores de ruptura mais plausíveis em quatro categorias: (i) gatilhos de demanda (revelação de excesso de capacidade); (ii) gatilhos de crédito (reprecificação do custo de financiamento); (iii) gatilhos de concentração de cliente único; e (iv) gatilhos macroeconômicos exógenos. Nenhum desses vetores opera de forma isolada — a plausibilidade de um cenário de correção mais severo aumenta na medida em que múltiplos gatilhos se ativam simultaneamente ou em sequência próxima.

9.2 Gatilho 1: revelação de excesso de capacidade (o precedente Meta Compute)

O anúncio da unidade *Meta Compute*, em 1º de julho de 2026, constitui o evento mais informativo já observado neste ciclo para avaliar como o mercado reage à quebra da premissa de “escassez perpétua de capacidade”. A reação de mercado ilustrou de forma nítida a mecânica de *repricing* esperada:

Ativo	Reação (1º de julho de 2026)	Interpretação
Meta Platforms	+6% a +8,8%	Mercado recompensa a possibilidade de monetizar capacidade ociosa via nova linha de receita
CoreWeave	-14%	Provedor GPU- <i>native</i> torna-se simultaneamente cliente e concorrente da Meta
Nebius	-17%	Mesmo padrão de exposição competitiva direta
Micron	> -10%	Fabricante de memória, sensível a qualquer sinal de desaceleração de demanda de componentes
AMD, Intel	-7% a -10%	Fornecedores de silício alternativo à Nvidia, também sensíveis à revisão de demanda agregada
Nvidia	-1,25%	Impacto comparativamente limitado, dado seu papel de fornecedor central e não de concorrente direto
Amazon	Queda moderada	Reação à ameaça competitiva de um quarto entrante de peso no mercado de nuvem

Se outras hyperscalers replicarem publicamente a mesma lógica — transformar capacidade originalmente planejada para uso interno em oferta comercial de terceiros — o mercado poderá interpretar esse padrão não como diversificação oportunista de receita, mas como confirmação de que as premissas de demanda subjacentes ao capex de US\$ 700+ bilhões anuais eram excessivamente otimistas, provocando reprecificação em cascata de fornecedores de hardware, provedores de nuvem GPU-*native* e desenvolvedores de data centers.

9.3 Gatilho 2: reprecificação de crédito e o precedente Oracle

O caso Oracle, detalhado na Seção 3.5, oferece o precedente mais avançado disponível de como o mercado de crédito reage quando a narrativa de *backlog* garantido encontra dúvidas concretas sobre capacidade de pagamento do cliente-âncora. Os elementos centrais desse precedente — queda de mais de 55% no valor de mercado, *spreads* de CDS em máximas históricas, corte de quadro de funcionários, e necessidade de captação adicional de capital via diluição acionária — constituem um roteiro replicável para qualquer outro fornecedor de infraestrutura cuja concentração de receita em um número reduzido de clientes de fundação seja revelada como excessiva. Fornecedores com padrão de concentração similar — identificados na Seção 4 — incluem, em graus variados, a CoreWeave (dependência de contratos com Microsoft, Meta e OpenAI) e provedores de crédito privado com exposição concentrada a um pequeno número de SPVs de data center.

Sinal de Alerta 6. *O mecanismo de contágio de crédito mais preocupante não é o risco de inadimplência de uma única companhia, mas o risco de que a dificuldade de sindicalização de dívida (já observada no caso de projetos financiados por Blue Owl que não encontraram investidores terceiros suficientes) se espalhe para outros SPVs, elevando o custo de financiamento para todo o setor e forçando as hyperscalers a recorrer, de forma crescente, a capital próprio ou dívida corporativa direta — exatamente o resultado que as estruturas de SPV foram originalmente desenhadas para evitar.*

9.4 Gatilho 3: falha ou atraso de IPO das startups de fundação

A OpenAI e a Anthropic sinalizaram intenção de abrir capital, com avaliações privadas recentes entre US\$ 850 bilhões e quase US\$ 1 trilhão. Esses eventos de listagem carregam risco de contágio bidirecional:

- **Se o IPO for adiado ou reduzido em valor:** fornecedores que dependem da liquidez gerada pela listagem para validar a capacidade de pagamento de compromissos contratuais plurianuais (Oracle sendo o caso mais exposto, com aproximadamente metade de seu *backlog* atrelado à OpenAI) sofreriam pressão adicional sobre suas próprias métricas de crédito, como já ocorreu de forma antecipada com o próprio adiamento sinalizado do IPO da OpenAI em julho de 2026;

- **Se o IPO for bem-sucedido, mas o desempenho pós-listagem for fraco:** o mercado público, com sua cadência trimestral de escrutínio e menor tolerância a prejuízos operacionais persistentes do que investidores de capital de risco privado, poderia forçar uma reavaliação abrupta do valor de mercado implícito de toda a cadeia de fornecedores que negociou contratos com base nas avaliações privadas anteriores;
- **Efeito de comparação cruzada:** a divergência de perfis financeiros entre OpenAI (receita majoritariamente de consumo, prejuízo de US\$ 14 bilhões projetado para 2026, fluxo de caixa positivo não antes de 2030) e Anthropic (receita majoritariamente corporativa, lucro operacional trimestral já projetado) tende a ser escrutinada de forma direta por analistas de mercado público, com potencial de agravar a pressão sobre qualquer uma das duas companhias que apresente desempenho relativo inferior ao esperado.

9.5 Gatilho 4: choque macroeconômico exógeno prolongado

Conforme detalhado na Seção 6, uma escalada renovada do conflito no Oriente Médio — reabertura incompleta do Estreito de Ormuz, retomada de hostilidades após expiração dos acordos de cessar-fogo sucessivos, ou extensão do choque de energia para além do horizonte atualmente precificado pelo mercado — elevaria ainda mais o custo de capital global em um momento no qual o setor de IA já demonstra dependência crescente de financiamento externo. Esse cenário, classificado por casas de análise como Charles Schwab como um cenário “adverso” ou “severo”, poderia produzir estagnação econômica na Europa e na Ásia, com bancos centrais inclinados a elevar ainda mais os juros para conter efeitos de segunda ordem sobre salários e preços — um ambiente diretamente adverso para qualquer estrutura de financiamento que dependa de juros baixos e crédito abundante para justificar múltiplos de avaliação elevados sobre fluxos de caixa futuros incertos.

9.6 Gatilho 5: revisão contábil ou regulatória sobre depreciação

Ainda que nenhum órgão regulador tenha, até a data deste relatório, imposto mudanças obrigatórias nas premissas de depreciação de GPUs discutidas na Seção 2.6, o escrutínio público crescente sobre essa prática eleva o risco de que auditores independentes, reguladores contábeis (como o FASB nos Estados Unidos) ou agências de classificação de risco de crédito passem a exigir maior conservadorismo nas premissas declaradas. Uma eventual revisão obrigatória de prazos de depreciação de cinco a seis anos para prazos mais próximos de dois a três anos produziria, segundo a estimativa citada por Burry, uma redução súbita e não-caixa nos lucros reportados de até US\$ 176 bilhões distribuídos entre as principais hyperscalers ao longo de 2026–2028 — um evento que, mesmo sem alterar o fluxo de caixa operacional subjacente, poderia provocar reprecificação abrupta de múltiplos de lucro (P/L) amplamente utilizados na avaliação dessas companhias.

9.7 Interação entre gatilhos: por que o risco agregado supera a soma das partes

O aspecto mais relevante desta seção é o reconhecimento de que os cinco gatilhos descritos não são mutuamente exclusivos nem estatisticamente independentes. Um choque de crédito (Gatilho 2) tende a se intensificar em um ambiente de juros mais altos (Gatilho 4); uma revelação de excesso de capacidade (Gatilho 1) tende a comprometer a percepção de mercado sobre a capacidade de conversão de *backlog* em receita (elemento central do Gatilho 2 no caso Oracle); e uma falha de IPO (Gatilho 3) reduz a disponibilidade de capital externo justamente no momento em que o Gatilho 4 já eleva seu custo. A teia de dependências mapeada exaustivamente na Seção 4 constitui, precisamente, o mecanismo de transmissão através do qual um choque localizado em qualquer um desses pontos pode se propagar para múltiplos outros nós do ecossistema em um intervalo de tempo relativamente curto.

10 Cenários Quantitativos de Correção

10.1 Nota metodológica

Os cenários apresentados nesta seção não constituem previsões pontuais, mas estimativas qualitativo-quantitativas construídas a partir de três fontes: (i) analogias históricas com ciclos de sobre-investimento em infraestrutura anteriores (fibra óptica 1999–2001, ferrovias britânicas década de 1840, telecomunicações 2000–2002); (ii) a magnitude de correções já observadas em subconjuntos do próprio ecossistema de IA ao longo de 2025–2026 (o caso Oracle, com queda de 55–59%, sendo o precedente mais direto e recente); e (iii) a sensibilidade de cada classe de ativo aos gatilhos identificados na Seção 9. Cenários de correção de mercado são, por natureza, sujeitos a incerteza substancial, e a probabilidade atribuída a cada cenário reflete um julgamento qualitativo e não um modelo estatístico calibrado.

10.2 Cenário Base (probabilidade estimada: moderada-alta): “Desinflação Ordenada”

Neste cenário, o ciclo de investimento em IA passa por uma correção gradual e escalonada ao longo de dezoito a trinta e seis meses, sem um evento único de ruptura sistêmica. Hyperscalers moderam o crescimento de capex para taxas de 15% a 25% ao ano (ante os atuais 60–77%), fornecedores de infraestrutura GPU-native mais alavancados (CoreWeave, Nebius) passam por reestruturação de dívida ou consolidação via fusões e aquisições, e o mercado acionário passa por uma rotação setorial — de fornecedores de infraestrutura para empresas de aplicação e usuários finais de IA que demonstrem monetização consistente. Estimativa de correção acumulada em ativos-chave: 25% a 40% de queda em fornecedores de hardware e provedores de nuvem GPU-native desde os picos observados; estabilização ou queda mais moderada (10% a 20%) nas quatro grandes hyperscalers, dado seu acesso a múltiplas fontes de receita não relacionadas a IA.

10.3 Cenário de Estresse (probabilidade estimada: moderada): “Repricing Abrupto de Crédito”

Neste cenário, um evento de crédito concreto — inadimplência ou reestruturação forçada de dívida por parte de um provedor GPU-native de porte relevante, ou dificuldade generalizada de sindicalização de novos SPVs — provoca um súbito reprecificação do custo de financiamento para todo o ecossistema, replicando em maior escala o precedente já observado no caso Oracle (Seção 3.5) e no episódio de dificuldade de sindicalização de dívida enfrentado pela Blue Owl (Seção 4.8). Estimativa de correção: 45% a 65% de queda em provedores de nuvem GPU-native altamente alavancados; 30% a 45% em fornecedores de silício com concentração de receita em um número reduzido de clientes; 20% a 35% nas hyperscalers de maior exposição a capex financiado por dívida (Meta e Oracle sendo as mais expostas dentro desse subconjunto, dado o uso intensivo de SPVs e a alavancagem já elevada, respectivamente); efeito de contágio limitado, mas mensurável, sobre o mercado de crédito privado mais amplo, com possível reprecificação de *spreads* em fundos de crédito estruturado não diretamente ligados a IA.

10.4 Cenário Severo (probabilidade estimada: baixa-moderada): “Convergência de Choques”

Neste cenário, dois ou mais dos gatilhos identificados na Seção 9 se ativam de forma próxima no tempo — por exemplo, uma escalada renovada do conflito no Oriente Médio (elevando ainda mais o custo de capital global) coincidindo com a falha ou fracasso de um IPO relevante (OpenAI ou Anthropic) e uma onda adicional de anúncios de excesso de capacidade por parte de hyperscalers adicionais replicando o padrão Meta Compute. Esse cenário se aproximaria, em magnitude, dos precedentes históricos de fibra óptica (1999–2001, com quedas de 90% ou mais em fornecedores de equipamento de rede e a inutilização de 85% a 95% da fibra instalada, segundo estimativas históricas) e do colapso das *dot-coms* de 2000–2002. Estimativa de correção: 60% a 85% de queda em provedores de nuvem GPU-native e fornecedores de silício de segunda linha altamente alavancados; 40% a 60% em fornecedores de silício de primeira linha (incluindo possivelmente a própria Nvidia, dado seu grau de concentração de receita nos mesmos clientes afetados); 25% a 45% nas hyperscalers de maior porte, ainda amparadas por diversificação de receita e balanços patrimoniais mais sólidos; efeito recessivo mensurável sobre a economia real dos Estados Unidos, dado o peso do capex de IA no crescimento do PIB americano em 2025–2026.

Cenário	Probabilidade qualitativa	Horizonte temporal	Correção estimada (fornecedores GPU-native)
Desinflação Ordenada	Moderada-alta	18–36 meses	25%–40%
Repricing Abrupto de Crédito	Moderada	6–18 meses	45%–65%
Convergência de Choques	Baixa-moderada	3–12 meses (fase aguda)	60%–85%

Por que nenhum cenário prevê colapso total da tecnologia subjacente

Mesmo no cenário mais severo, a analogia histórica mais próxima — a bolha de fibra óptica — é instrutiva: a infraestrutura física instalada durante o excesso especulativo de 1999–2001, ainda que subutilizada por anos, tornou-se posteriormente a espinha dorsal da expansão de banda larga e da própria revolução da computação em nuvem das duas décadas seguintes. Da mesma forma, mesmo em um cenário de correção severa de valuation e de reestruturação de dívida no ecossistema de IA, é razoável esperar que parte relevante da capacidade computacional instalada— ainda que sob nova estrutura de propriedade e a preços de aquisição muito mais baixos — permaneça economicamente útil e seja eventualmente absorvida por demanda genuína ao longo da década seguinte.

10.5 Sensibilidade dos cenários aos desenvolvimentos macroeconômicos

A probabilidade relativa de cada um dos três cenários descritos é diretamente sensível à evolução dos fatores macroeconômicos mapeados na Seção 6. Uma resolução duradoura do conflito no Oriente Médio, com normalização completa do tráfego no Estreito de Ormuz e recuo do petróleo para níveis próximos aos anteriores ao conflito (abaixo de US\$ 70 por barril), reduziria materialmente a probabilidade do Cenário Severo e favoreceria o Cenário Base. Inversamente, uma escalada renovada das hostilidades, combinada com um Federal Reserve e um Banco Central Europeu que optem por elevações adicionais de juros para conter efeitos de segunda ordem sobre a inflação, deslocaria a distribuição de probabilidade na direção dos Cenários de Estresse e Severo.

11 Matriz de Exposição por Classe de Ativo e Ordem de Impacto Temporal

11.1 Estrutura da matriz

Esta seção conclusiva organiza os ativos mais relevantes do ecossistema mapeado neste relatório em três categorias de impacto temporal — primeira, segunda e terceira ordem — de acordo com a proximidade estrutural de cada ativo aos gatilhos de ruptura identificados na Seção 9, e complementa a análise com uma categoria de ativos que tendem a se beneficiar, no curto e médio prazo, de uma eventual correção do ciclo de IA.

11.2 Ativos de primeira ordem: impacto imediato e direto

Constituem o conjunto de ativos com exposição mais direta e sem intermediação a qualquer um dos gatilhos de ruptura — tipicamente companhias cuja receita depende, em proporção elevada, de um número reduzido de clientes dentro do próprio ecossistema de IA, ou cuja estrutura de capital já exhibe sinais de tensão observável.

Categoria	Exemplos e racional
Provedores de nuvem GPU-native	CoreWeave, Nebius, Lambda — alavancagem elevada, concentração de receita em poucos clientes hyperscalers/startups, e exposição direta comprovada ao anúncio Meta Compute (quedas de 14–17% em uma única sessão)
Fornecedores de infraestrutura com concentração de cliente único	Oracle (concentração de ≈ 47–54% do RPO na OpenAI) — já demonstrou, ao longo de 2025–2026, o padrão de correção mais severo entre companhias de grande porte do ecossistema (queda superior a 55%)
Startups de fundação pré-IPO com queima de caixa elevada	OpenAI — projeção de queima de caixa de US\$ 27 bi (2026) e US\$ 63 bi (2027), dependência de sucessivas rodadas de capital externo e de sucesso do IPO planejado
Gestoras de crédito privado com exposição concentrada a SPVs de data center	Blue Owl e pares — diretamente expostas a qualquer dificuldade de sindicalização ou reprecificação de risco nas estruturas mapeadas na Seção 4.8
Fabricantes de componentes com alta correlação de demanda ao ciclo de capex	Fabricantes de memória (DRAM/HBM) e equipamentos de rede — historicamente os primeiros a sofrer correção em ciclos de desaceleração de capex, como demonstrado pela reação de mercado ao anúncio Meta Compute

11.3 Ativos de segunda ordem: impacto derivado, com defasagem de trimestres

Compreende companhias cuja exposição ao ciclo de IA é relevante, mas mediada por diversificação de receita, poder de mercado ou acesso a fontes alternativas de financiamento que retardam — ainda que não eliminem — a transmissão de um eventual choque.

Categoria	Exemplos e racional
Fornecedores de silício de primeira linha	Nvidia — concentração de receita elevada no segmento de data center ($\approx 90\%$ do total), mas com margem bruta e posição de mercado ainda dominantes; a Seção 9.1 já demonstrou reação de mercado mais moderada da Nvidia ($-1,25\%$) frente a choques de demanda no restante da cadeia
Hyperscalers diversificadas de grande porte	Microsoft, Amazon, Alphabet — capex elevado e crescente, mas amparado por múltiplas linhas de receita não diretamente atreladas a IA (produtividade empresarial, comércio eletrônico, publicidade, buscas) que absorveriam parcialmente qualquer choque de curto prazo
Fabricantes de silício alternativo	AMD, Broadcom — diversificação parcial de clientes, mas ainda expostos a compromissos concentrados (caso AMD–OpenAI) que os tornam sensíveis a qualquer reavaliação da capacidade de pagamento desses clientes
Fundos de índice e carteiras passivas de grande escala	Fundos que replicam o S&P 500 — exposição estrutural de mais de um terço do índice às “Magnificent Seven”, com transmissão de qualquer choque setorial ampliada pela concentração recorde documentada na Seção 7.6
Bancos com exposição indireta via linhas de crédito a fundos de crédito privado	Exposição direta reportada em torno de apenas $0,8\%$ dos ativos totais (Federal Reserve Bank of Chicago), mas com exposição indireta não quantificada através de linhas de crédito a fundos de crédito privado

11.4 Ativos de terceira ordem: impacto sistêmico e macroeconômico difuso

Compreende classes de ativos e segmentos da economia real cuja exposição ao ciclo de IA é indireta, mas que poderiam ser afetados caso um choque de magnitude suficiente (Cenário Severo da Seção 10) se propague para a economia agregada.

Categoria	Exemplos e racional
Mercado imobiliário comercial ligado a data centers	Desenvolvedores e REITs especializados em data centers em regiões de expansão recente (Texas, Louisiana, Virgínia) — exposição a taxas de vacância crescentes e reprecificação de prêmios de aluguel caso projetos de energia dedicada sofram atrasos ou cancelamentos
Crescimento do PIB americano e emprego em construção civil especializada	O capex de IA tem sido citado como um dos principais motores marginais de crescimento do PIB dos EUA em 2025–2026; uma desaceleração abrupta teria efeito mensurável sobre estatísticas de crescimento agregado e emprego em construção de infraestrutura especializada
Mercados emergentes exportadores de commodities eletrônicas e semicondutores	Economias asiáticas (Taiwan, Coreia do Sul, partes do Sudeste Asiático) com cadeias de suprimento de semicondutores e componentes eletrônicos vinculadas à demanda do ciclo de IA
Mercado de crédito privado mais amplo	Possível reprecificação de <i>spreads</i> em fundos de crédito estruturado não diretamente ligados a IA, caso a confiança do mercado em estruturas de SPV se deteriore de forma generalizada
Consumidores finais em mercados de energia elétrica residencial	Comunidades próximas a grandes data centers já reportam repasse de custos de infraestrutura elétrica a tarifas residenciais; uma desaceleração do ciclo poderia, paradoxalmente, aliviar essa pressão específica

11.5 Ativos que tendem a se beneficiar no curto e médio prazo

Nem todo desfecho do ciclo de IA é necessariamente negativo para a totalidade dos ativos financeiros. Um conjunto identificável de classes de ativos tende a se beneficiar, relativamente, em cenários de desaceleração ou correção do ciclo de investimento em infraestrutura de IA:

- **Empresas de *software* tradicional e aplicação vertical penalizadas pelo entusiasmo especulativo com IA de infraestrutura.** O próprio Michael Burry rotacionou parte de sua carteira para nomes como Adobe, Autodesk, Salesforce e Veeva Systems — companhias com fluxo de caixa estabelecido, mas cujas ações, segundo essa tese, foram relativamente penalizadas pela migração de capital especulativo para o segmento de infraestrutura física de IA;
- **Companhias de tecnologia com monetização de IA já validada e menor intensidade de capital físico próprio.** Empresas que utilizam capacidade de terceiros (via API) para incorporar IA aos próprios produtos, sem necessidade de capex direto em infraestrutura física, tendem a se beneficiar de eventual queda no custo de inferência decorrente de excesso de capacidade instalada por terceiros;
- **Ativos de renda fixa de curto prazo e caixa, em um cenário de juros mais altos por mais tempo.** O ambiente macroeconômico descrito na Seção 6 — com Federal Reserve e BCE sinalizando postura mais restritiva — favorece relativamente instrumentos de renda fixa de curta duração e posições de caixa, tanto pelo carregamento de juros mais elevado quanto pela proteção relativa contra a volatilidade de ativos de risco concentrados no ciclo de IA;
- **Setor de energia tradicional (petróleo, gás natural) no curto prazo, dado o choque de oferta do Oriente Médio.** Conforme discutido na Seção 6, o choque de oferta já beneficiou, no curto prazo, produtores de energia fora da zona de conflito direto, bem como fornecedores de geração via gás natural contratados pelas próprias hyperscalers como alternativa de mais rápida implementação à energia nuclear;
- **Fundos de índice de ponderação igualitária (*equal-weight*) como veículo de realocação defensiva.** Conforme discutido na Seção 7.6, estratégias de ponderação igualitária do S&P 500 permitem a investidores reduzir exposição à concentração recorde nas “Magnificent Seven” sem abandonar por completo a exposição à renda variável americana, funcionando como uma forma de disciplina automática de realização de lucro em nomes que se valorizaram desproporcionalmente.

11.6 Considerações finais

A tese central deste relatório — de que o ciclo de investimento em infraestrutura de Inteligência Artificial combina avanço tecnológico genuíno com um grau de má alocação de capital historicamente comparável a ciclos anteriores de sobre-investimento em infraestrutura — não implica uma previsão determinística de colapso iminente, tampouco nega o valor econômico real já demonstrado por segmentos específicos do setor. Implica, isto sim, que investidores, alocadores de capital e formuladores de política devem monitorar de perto os cinco vetores de ruptura mapeados na Seção 9, a evolução da conjuntura macroeconômica global detalhada na Seção 6 — particularmente o desfecho do choque de energia do Oriente Médio e a trajetória de política monetária de Estados Unidos e zona do euro — e o comportamento revelado dos agentes de mercado mais informados, cuja postura crescentemente cautelosa, documentada de forma extensa na Seção 7, constitui um dos sinais mais relevantes disponíveis para avaliar a maturidade e o risco remanescente deste ciclo de investimento.

Fim do documento. Este relatório reflete informações públicas disponíveis até 5 de julho de 2026 e está sujeito a revisão à medida que novos dados se tornem disponíveis.